

FINAL PROJE RAPORU

Ders/Dönem: Derin Öğrenme (FET312) – Güz 2026

Proje Başlığı: Dermatoskopik Cilt Lezyonları Sınıflandırması

Ekip Adı: DermAI

Ekip Üyeleri:

22040301030- Şevval Arslan

sevalarslan@stu.topkapi.edu.tr

23040301081-Miyase Eda Erol

miyaseedaerol@stu.topkapi.edu.tr

23040301071-Zeynep Şafak

zeynepsafak@stu.topkapi.edu.tr

23040301093-Eylül Erdemci

eylulerdemci@stu.topkapi.edu.tr

23040301108-Zeynep Ekinci

zeynepekinci@stu.topkapi.edu.tr

GitHub/Repo Bağlantısı:

https://github.com/iamsevval/SkinCancer_DL_Project

Youtube Linki: <https://youtu.be/USt4oaalS6s>

1) Problem Tanımı & Motivasyon

- **İş/Bilimsel Soru:** İnsan derisi üzerindeki lezyonların doğru sınıflandırılması, cilt kanserinin erken teşhisini ve doğru tedavi planlaması açısından kritik öneme sahiptir. Bu projede, **HAM10000** veri setini kullanarak dermatoskopik görüntülerden 7 farklı cilt lezyonu tipini (MEL, NV, BCC, AKIEC, BKL, DF, VASC) sınıflandıran, yüksek başarılı Derin Öğrenme (Deep Learning) modelleri geliştirilmiştir. Proje kapsamında PyTorch kütüphanesi kullanılmış, sıç (shallow) CNN modelleri ile gelişmiş Transfer Learning mimarileri (ResNet, EfficientNet vb.) karşılaştırılmıştır.
- **Görev Türü:** Sınıflandırma (Classification) – Dermatoskopik cilt görüntülerini 7 farklı sınıfaya ayırmayı amaçlamaktadır. (7 sınıf: MEL, NV, BCC, AKIEC, BKL, DF, VASC)
- **Hedef Değişken(ler):**
 - Sınıf: Lezyon tipi (categorical, 7 sınıf)
 - Birimleri: sınıf etiketleri (string)
 - Pozitif sınıf: MEL (Melanom)
- **Başarı Kriterleri:**
 - Accuracy ≥ 0.80
 - F1-Score ≥ 0.75
 - ROC-AUC (multiclass) ≥ 0.80

2) Proje Yönetimi

- **Önemli Noktalar ve Zaman Çizelgesi :**
 - 1.Hafta: Veri seti seçimi ve proje planlaması (20-27 Ekim)
 - 2.Hafta: Veri inceleme ve ön işleme (3-16 Kasım)
 - 3-4. Hafta: Model tasarımları ve geliştirme(17-30 Kasım)
 - 5-6. Hafta: Hiperparametre optimizasyonu(1–14 Aralık)
 - 7.Hafta: Performans analizi ve model karşılaştırması(15–28 Aralık)
 - 8.Hafta: Rapor ve sunum hazırlanması(5–31 Ocak)

Roller ve Sorumluluklar

Final Aşaması – Derin Öğrenme Modelleri:

- **Şevval Arslan:**
(Modellerim GitHub hesabındaki `Transfer_learning_and_fine_tuning` dosyasındaki ipynb dosyalarındaki eğitim sürecinden elde edilmiştir. Diğer dosyalar deneysel analiz amaçlı örneklerdir.)

ResNet-50 Modeli: Convolutional tabanlı giriş katmanı + Residual (skip connection) bloklar (ResNet50, Bottleneck) + ReLU aktivasyonu + Batch Normalization + Global Average Pooling + Fully Connected (Linear) layer \rightarrow 7 sınıfı Output Layer

EfficientNet-B0 Modeli: ImageNet ön-eğitimli EfficientNet-B0 tabanlı yapı + MBConv blokları + Swish/SiLU aktivasyonu + Squeeze-and-Excitation (SE) modülleri + Global Average Pooling + Dropout + Fully Connected (Linear) layer \rightarrow 7 sınıfı Output Layer

- **Zeynep Ekinci:**

ResNet18 Modeli: (18 katmanlı residual yapı, 3×3 Conv + Skip Connections + Global Average Pooling + Fully Connected + 7 sınıfı Output Layer)

Xception Modeli: (Depthwise Separable Conv tabanlı Entry–Middle–Exit Flow + ReLU + Global Average Pooling + Fully Connected + 7 sınıfı Output Layer)

- **Zeynep Şafak:**

EfficientNet-B3 Modeli: Convolutional tabanlı bloklar + MBConv derinleştirilmiş bloklar + Swish aktivasyonu + Squeeze-and-Excitation (SE) modülleri + Global Average Pooling + Dropout + Fully Connected (Linear) layer → 7 sınıfı Output Layer

ResNet-34 Modeli: Convolutional tabanlı giriş katmanı + Residual (skip connection) bloklar (ResNet34) + ReLU aktivasyonu + Batch Normalization + Global Average Pooling + Fully Connected (Linear) katman → 7 sınıfı Output Layer

- **Miyase Eda Erol:**

EfficientNet-B1 Modeli: ImageNet ön-eğitimli EfficientNet-B1 tabanlı yapı + MBConv blokları + Swish/SiLU aktivasyonu + Global Average Pooling + Fully Connected (7 sınıfı Output Layer) + Softmax

DenseNet-121 Modeli: ImageNet ön-eğitimli DenseNet121 tabanlı yapı + Yoğun (Dense) bağlantılı konvolüsyonel bloklar + Batch Normalization + ReLU aktivasyonu + Global Average Pooling + Fully Connected (7 sınıfı Output Layer) + Softmax

- **Eylül Erdemci:**

EfficientNet-B0 Modeli= (Compound Scaling tabanlı yapı + MBConv blokları + Swish aktivasyonu + Global Average Pooling + Fully Connected + 7 sınıfı Output Layer)

ResNet101 Modeli= (101 katmanlı residual yapı + 3×3 Conv + Skip Connections + Global Average Pooling + Fully Connected + 7 sınıfı Output Layer)

Çıktılar:

- Proje raporu
- Jupyter Notebook kod dosyaları (her üye farklı derin öğrenme modelleri)
- Eğitim grafikleri ve performans metrikleri
- Proje sunum slaytları
- GitHub/Repo: https://github.com/iamsevval/SkinCancer_DL_Project

3) İlgili Çalışmalar (Literatür Taraması)

- Tschandl et al., "HAM10000 Dataset: A Large Collection of Multi-Source Dermatoscopic Images of Common Pigmented Skin Lesions", *Sci Data*, 2018
- Esteva et al., "Dermatologist-level classification of skin cancer with deep neural networks", *Nature*, 2017
- [1] Tschandl, P., Rosendahl, C., & Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161. <https://doi.org/10.1038/sdata.2018.161>
- [2] Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115-118.
- [3] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).
- [4] Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *International conference on machine learning* (pp. 6105-6114). PMLR.
- [5] Paszke, A., et al. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. *Advances in Neural Information Processing Systems*, 32.

4) Veri Seti ve Ön İşleme (Veri Yönetimi)

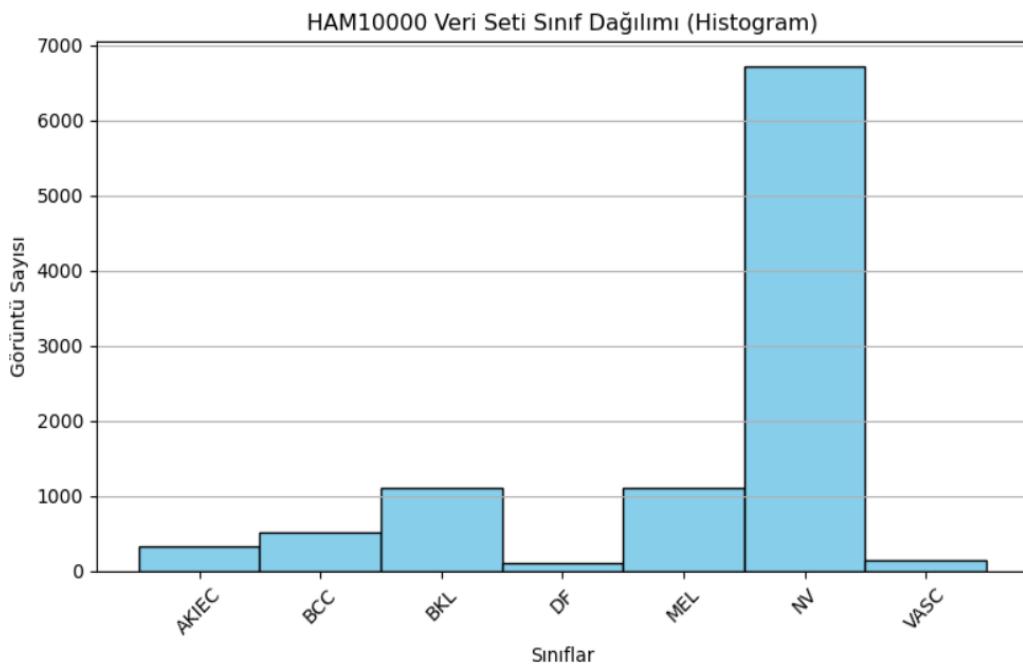
Veri Seti Kaynağı: Projede kullanılan veri seti, Harvard Dataverse tarafından yayınlanan ve Kaggle üzerinden erişilen **HAM10000 ("Human Against Machine with 10000 training images")** veri setidir.

- Link: <https://www.kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000/data>

a. Veri Seti Boyutu ve Özellikleri: Veri seti toplamda **10.015** adet dermatoskopik görüntünden oluşmaktadır. Orijinal görüntüler RGB formatında olup, modellerimize giriş için **[Örn: 224x224]** boyutlarına yeniden boyutlandırılmış ve normalize edilmiştir.

b. Sınıf Dağılımı ve Etiketler: Sınıflandırma işlemi 7 farklı etiket (label) üzerinden yapılmaktadır. Veri seti doğası gereği dengesiz (imbalanced) bir yapıdadır. Sınıf dağılımı şöyledir:

- **NV (Melanocytic nevi):** [Örn: 6705] adet
- **MEL (Melanoma):** [Örn: 1113] adet
- **BKL (Benign keratosis):** [Örn: 1099] adet
- **BCC (Basal cell carcinoma):** [Örn: 514] adet
- **AKIEC (Actinic keratoses):** [Örn: 327] adet
- **VASC (Vascular lesions):** [Örn: 142] adet
- **DF (Dermatofibroma):** [Örn: 115] adet



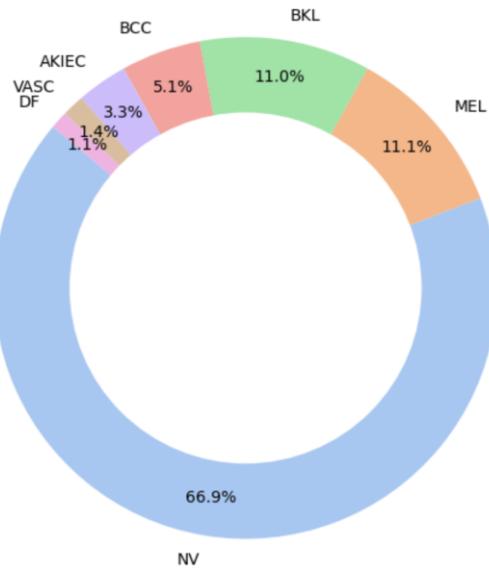
c. Veri Artırma (Data Augmentation) ve Özellik Mühendisliği Stratejisi

Projede kullanılan HAM10000 veri setindeki sınıf dengesizliğini (Class Imbalance) yönetmek ve modellerin ezberlemesini (Overfitting) önlemek amacıyla, eğitim aşamasında "On-the-fly" (Eş zamanlı) veri artırma teknikleri uygulanmıştır. `torchvision.transforms` kütüphanesi ile uygulanan işlemler ve seçilme nedenleri şunlardır:

- **Random Rotation (Rastgele Döndürme):** Lezyonların vücuttaki konumu dermatoskopik açıdan tanışal bir fark yaratmadığı için, görüntülere model mimarisine bağlı olarak **± 10 ila ± 20 derece aralığında** rastgele döndürme uygulanmıştır. Bu sayede modelin yönelimden bağımsız (rotation invariant) özellikler öğrenmesi sağlanmıştır.
- **Random Horizontal & Vertical Flip (Yatay ve Dikey Çevirme):** $p=0.5$ olasılıkla uygulanmıştır. Lezyonun sağa veya sola bakması kanser tanısını değiştirmemişti için bu işlem veri çeşitliliğini efektif olarak artırmaktadır.
- **Color Jitter (Renk Titreşimi):** Farklı dermatoskop cihazlarının ışıklandırma koşullarını simüle etmek amacıyla; Parlaklık (Brightness), Kontrast ve Doygunluk değerlerinde **0.2 oranında** rastgele değişimler uygulanmıştır.
- **Normalization (Normalizasyon):** Tüm görüntüler, ImageNet veri setinin istatistiksel değerleri (Mean: [0.485, 0.456, 0.406], Std: [0.229, 0.224, 0.225]) kullanılarak normalize edilmiş, böylece gradyan optimizasyonunun daha stabil ve hızlı olması sağlanmıştır.

Veri Seti Boyutu ve Dağılım Değişimi: Uygulanan veri artırma işlemi bellek üzerinde dinamik olarak gerçekleştiği için fiziksel diskteki görüntü sayısı (10.015) sabit kalmıştır. Ancak model, eğitim boyunca her görüntünün farklı bir varyasyonunu görerek efektif olarak artırılmış bir veri setiyle eğitilmiştir. Sınıf dağılımındaki dengesizliği yönetmek için ise **Weighted Random Sampler** ve **Weighted Cross Entropy Loss** teknikleri stratejik olarak kullanılarak, modellerin azınlık sınıflara (MEL, VASC vb.) karşı duyarlılığı artırılmıştır.

HAM10000 Veri Seti Orijinal Sınıf Dağılımı (İmbalance Yapı)



d. Eğitim-Test Bölümlemesi (Train-Test Split Stratejisi)

Veri setindeki dengesiz yapı nedeniyle, veri setinin ayrıştırılmasında **Stratifikasyon (Tabakalama)** temelli yöntemler esas alınmıştır. Bu sayede nadir görülen sınıfların (DF, VASC) eğitim ve test setlerine orijinal oranlarıyla dağıtılması garanti edilmiştir.

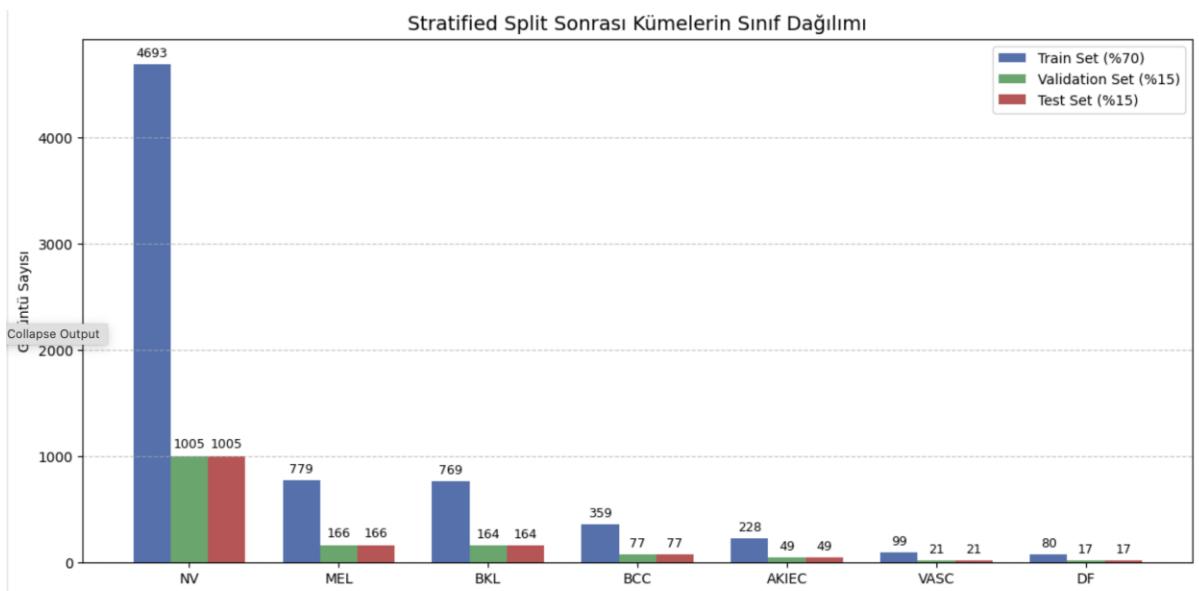
Proje genelinde modellerin eğitimi ve değerlendirilmesinde hibrit bir yaklaşım izlenmiştir:

- Stratified Shuffle Split:** Veri seti genel performansı ölçmek için **%70 Eğitim, %15 Doğrulama ve %15 Test** oranlarında ayrılmıştır.
- Stratified K-Fold:** Bazı modellerin (Örn: EfficientNet-B1) eğitiminde ise modelin kararlılığını artırmak ve validasyon başarısını çapraz doğrulamak amacıyla **Stratified K-Fold** yöntemi kullanılmıştır.

Nihai test setindeki dağılım korunmuş olup, sınıf oranları aşağıdaki gibi gibidir:

- Eğitim Seti:** %70 (7010 Görüntü)
- Doğrulama (Val) Seti:** %15 (1502 Görüntü)
- Test Seti:** %15 (1503 Görüntü)

Eğitim ve Test setlerinin sınıf dağılımlarının tutarlılığı aşağıdaki grafikte gösterilmiştir. Görüldüğü üzere, her iki kümede de sınıf oranları korunmuş, veri sızıntısı (data leakage) engellenmiştir.



5) Yöntemler ve Mimari

Geliştirilmiş Modelleri ve Mimari Detayları (Hyperparameter Tuning)

Bu bölümde, vize aşamasındaki "Base" modellerin üzerine inşa edilen, Transfer Learning (Transfer Öğrenme) ve Fine-Tuning teknikleri içeren gelişmiş mimariler detaylandırılmıştır. Tüm modeller PyTorch framework'ü ile geliştirilmiştir.

5.1. Model 1 (SkinClassifierCNN): ResNet50 / EfficientNet-B0 (Geliştirici: Sevval Arslan)

a) ResNet50

Uyarı / Açıklama: Github hesabında proje kapsamında yapılan deneylerde, transfer learning ve fine-tuning aşamaları başlangıçta ayrı dosyalar altında bağımsız olarak test edilmiştir. Nihai model ve raporda sunulan tüm sonuçlar, bu iki yaklaşımın birlikte ve sistematik şekilde uygulandığı **Transfer_learning_and_fine_tuning** dosyasındaki eğitim sürecinden elde edilmiştir. Ayrı dosyalar, karşılaştırma ve deneysel analiz amacıyla GitHub reposunda korunmuştur.

Mimari Seçimi: Vize aşamasında kullanılan basit sınıflandırıcı olan SkinClassifierBase yerine, derinliği, katman yapısı ve özellik çıkarım yeteneği kanıtlanmış olan ResNet50 mimarisi tercih edilmiştir. ResNet50, residual bağlantılar sayesinde derin ağlarda ortaya çıkan vanishing gradient problemini önler ve çok katmanlı yapısına rağmen eğitim stabilitesini korur. Bu özellikler, deri lezyonlarının sınıflandırılmasında kritik olan ince görsel ayrıntıların öğrenilmesine olanak sağlamaktadır. Ayrıca, önceden ImageNet veri seti üzerinde eğitilmiş ağırlıkların transfer learning için kullanılması, sınırlı veri seti üzerinde daha hızlı ve etkili bir öğrenme süreci sağlamıştır.

Teknik: Model eğitimi sırasında veri çeşitliliğini artırmak için ileri veri artırma (data augmentation) teknikleri uygulanmıştır. Bunlar arasında yatay ve dikey çevirme, rastgele döndürme, renk jitter ve yeniden boyutlandırma gibi işlemler yer almaktadır. Ayrıca, sınıf dengesizliğini gidermek için eğitim sırasında her

sınıfa göre ağırlıklandırılmış CrossEntropyLoss kullanılmıştır. Bu yaklaşım, nadir görülen lezyon sınıflarının model tarafından ihmal edilmesini önleyerek genel sınıflandırma performansını artırmıştır.

Hyperparameter Tuning: Modelin performansını optimize etmek amacıyla öğrenme hızı (learning rate) ve mini-batch boyutu (batch size) üzerinde bir hiperparametre araştırması gerçekleştirilmiştir. Deneme aşamasında iki farklı öğrenme hızı ($[1e-3, 1e-4]$) ve iki farklı batch boyutu ($[16, 32]$) kullanılarak çapraz doğrulama yöntemiyle modelin doğruluk ve F1 skoru değerlendirilmiştir. Bu süreç, hem modelin hızlı ve stabil öğrenmesini hem de overfitting riskinin minimize edilmesini sağlamıştır.

Yöntem: Model eğitimi iki aşamalı bir strateji ile yürütülmüştür. İlk aşamada, ResNet50 mimarisi ImageNet ağırlıklarıyla başlatılmış ve modelin tamamı, veri setine genel adaptasyon sağlama amacıyla belirlenen optimum öğrenme oranı (0.0001) ile eğitilmiştir. İkinci aşamada ise fine-tuning (ince ayar) stratejisi devreye alınmıştır. Bu aşamada öğrenme oranı daha da düşürülerek ($1e-5$) ve ReduceLROnPlateau kullanılarak, model ağırlıklarının (weights) lezyonların ince detaylarına odaklanacak şekilde hassas bir biçimde güncellenmesi sağlanmıştır. Bu kademeli öğrenme stratejisi, modelin hem genel özellik çıkarım yeteneğini korumasını hem de dermatoskopik görüntülerdeki spesifik örüntülerini öğrenmesini sağlamıştır.

Optimizer: Eğitim sırasında Adam optimizasyon algoritması kullanılmıştır. Adam, adaptif öğrenme oranı özelliği sayesinde her parametre için farklı hızlarda güncelleme yapabilmekte ve derin ağlarda stabil bir eğitim süreci sağlamaktadır. Fine-tuning aşamasında ise öğrenme oranı daha düşük bir değer ile ayarlanmış ve ReduceLROnPlateau scheduler kullanılarak doğruluk iyileşmesi durduğunda öğrenme oranı otomatik olarak azaltılmıştır.

Learning Rate: Transfer learning aşamasında optimum performans için 0.0001 değeri, fine-tuning aşamasında ise daha hassas güncellemeler için $1e-5$ olarak belirlenmiştir. Bu düşük öğrenme oranları, önceden öğrenilmiş ağırlıkların bozulmasını önleyerek modelin genel performansını korumasını sağlamıştır.

Batch Size: Eğitim sırasında modelin bellek kullanımı ve stabil güncellemeler açısından 32 batch boyutu seçilmiştir. Hyperparameter tuning aşamasında farklı batch boyutları test edilmesine rağmen, 32, doğruluk ve F1 skorunu optimize eden değer olarak belirlenmiştir.

Elde Edilen Optimum Parametreler: Hiperparametre araştırması ve fine-tuning sonrası modelin optimum parametreleri şu şekilde belirlenmiştir: ResNet50 mimarisi, öğrenme oranı 0.0001 (transfer learning) ve $1e-5$ (fine-tuning), batch boyutu 32, Adam optimizer kullanımı ve sınıf ağırlıklı CrossEntropyLoss fonksiyonu. Bu parametreler ile model, test veri setinde yüksek doğruluk ve F1 skorları elde ederek hem sınıflar arası dengeli performans hem de kanserli lezyonların doğru sınıflandırılması açısından güçlü bir sonuç göstermiştir.

Sonuç: Seçilen ResNet50 mimarisi, derinliği ve residual yapısı sayesinde deri lezyonlarını sınıflandırmada yüksek performans göstermiştir.

b) EfficientNet-B0

Uyarı / Açıklama: GitHub hesabında proje kapsamında yapılan deneylerde, transfer learning ve fine-tuning aşamaları başlangıçta ayrı dosyalar (Classifier_training ve Fine_tuning) altında bağımsız olarak test edilmiştir. Nihai model ve raporda sunulan tüm sonuçlar, bu iki yaklaşımın birlikte ve sistematik şekilde uygulandığı **Transfer_learning_and_fine_tuning** dosyasındaki eğitim sürecinden elde edilmiştir. Ayrı dosyalar, karşılaştırma ve deneysel analiz amacıyla GitHub reposunda korunmuştur.

Mimari Seçimi: Vize aşamasında kullanılan temel CNN mimarisi (SkinClassifierBase) yerine, daha derin ve daha güçlü özellik çıkarımı yapabilen EfficientNet-B0 mimarisi tercih edilmiştir. EfficientNet-B0, literatürde özellikle görüntü sınıflandırma problemlerinde başarılı sonuçlar vermiş modern bir derin öğrenme mimarisidir. EfficientNet-B0 mimarisi, compound scaling yaklaşımını temel alarak ağı derinliği, genişliği ve giriş çözümünü dengeli biçimde ölçeklendirmektedir. Bu sayede sınırlı sayıda parametre kullanmasına rağmen yüksek temsil gücü elde edilmekte ve özellikle tıbbi görüntü analizlerinde yüksek genellemeye başarımı sağlanmaktadır.

Bu çalışmada EfficientNet-B0 modeli, ImageNet veri seti üzerinde önceden eğitilmiş (pretrained) ağırlıklar kullanılarak başlatılmıştır. Modelin son sınıflandırıcı katmanı, 7 sınıflı cilt lezyonu sınıflandırma problemine uygun olacak şekilde yeniden yapılandırılmıştır.

Teknik Yaklaşım: Model eğitimi, transfer learning ve fine-tuning stratejilerinin birlikte kullanıldığı iki aşamalı bir süreç olarak gerçekleştirilmiştir. Bu yaklaşım, modelin hem genel görsel özellikleri etkin şekilde kullanmasını hem de probleme özgü detayları öğrenmesini sağlamıştır. Transfer learning aşamasında EfficientNet-B0 mimarisi, ImageNet üzerinde önceden eğitilmiş ağırlıklarla başlatılmış ve tüm ağı düşük öğrenme oranı ile eğitilmiştir. Bu sayede genel görsel temsiller korunurken, probleme özgü özellikler kontrollü biçimde güncellenmiştir. Bu aşamanın amacı, genel görsel özelliklerin korunarak cilt lezyonlarına özgü ayrımcı özelliklerin öğrenilmesidir.

Fine-tuning aşamasında ise modelin tüm katmanları eğitime açılmıştır. Daha düşük bir öğrenme oranı kullanılarak, ağıın dermatoskopik detaylara daha hassas hale gelmesi hedeflenmiştir. Bu iki aşamalı eğitim süreci, aşırı öğrenmenin (overfitting) önüne geçerken sınıflar arası ayrim gücünü artırılmıştır.

Hyperparameter Tuning: Model performansını optimize etmek amacıyla öğrenme oranı (learning rate) ve batch size parametreleri üzerinde deneysel bir hiperparametre arama süreci uygulanmıştır. Bu süreçte, farklı parametre kombinasyonları kısa süreli eğitimlerle test edilmiştir. Öğrenme oranı için $1e-3$ ve $1e-4$ değerleri, batch size için ise 16 ve 32 değerleri denenmiştir. Her kombinasyon için model 3 epoch boyunca eğitilmiş ve doğrulama kümesi üzerindeki macro F1-score hesaplanmıştır. Veri setinde ciddi sınıf dengesizliği bulunması nedeniyle, hiperparametre seçiminde doğruluk (accuracy) yerine macro F1-score temel değerlendirme metriği olarak kullanılmıştır.

Yöntem: Eğitim sürecinde, veri setindeki sınıf dengesizliğini dengelemek amacıyla sınıf ağırlıklı Cross Entropy Loss fonksiyonu kullanılmıştır. Ayrıca modelin genelleme yeteneğini artırmak için eğitim verisi üzerinde rastgele yatay/dikey çevirme, 20 derece döndürme ve parlaklık/kontrast değişimlerini içeren (ColorJitter) veri zenginleştirme (data augmentation) teknikleri uygulanmıştır." Özellikle az örnek sayısına sahip sınıflar (örneğin df, vasc, aiec) daha yüksek ağırlıklarılarak modelin bu sınıflara karşı duyarlılığı artırılmıştır. Model performansı, farklı yönlerden değerlendirme yapılabilmesi amacıyla birden fazla metrik kullanılarak ölçülümüştür. Bu metrikler arasında Accuracy, Balanced Accuracy, Macro F1-Score ve çok sınıflı ROC-AUC (one-vs-rest) bulunmaktadır. Bu metrikler, hem genel başarıyı hem de az temsil edilen sınıflardaki performansı daha sağlıklı biçimde yansıtmaktadır.

Optimizer: Model eğitimi için Adam optimizer tercih edilmiştir. Adam optimizer, momentum ve adaptif öğrenme oranı mekanizmalarını birleştirerek hızlı yakınsama, kararlı bir eğitim süreci ve gürültülü gradyanlara karşı dayanıklılık sağlamaktadır. Bu özellikleri nedeniyle transfer learning ve fine-tuning senaryoları için uygun bir optimizasyon yöntemidir.

Learning Rate: Transfer learning aşamasında öğrenme oranı $1e-4$ olarak belirlenmiştir. Bu düşük öğrenme oranı, önceden öğrenilmiş ağırlıkların bozulmadan korunmasını ve kararlı bir eğitim süreci yürütülmesini

sağlamıştır. Fine-tuning aşamasında ise öğrenme oranı daha da düşürülerek $1e-5$ olarak ayarlanmıştır. Tüm katmanların eğitime açıldığı bu aşamada, daha hassas ağırlık güncellemleri hedeflenmiştir. Ayrıca öğrenme oranı, doğrulama macro F1-score değerine bağlı olarak ReduceLROnPlateau zamanlayıcısı ile dinamik şekilde azaltılmıştır.

Batch Size: Yapılan deneyler sonucunda batch size = 32 değerinin en iyi performansı sağladığı gözlemlenmiştir. Daha küçük batch size değerleri eğitim kararlılığını olumsuz etkilerken, daha büyük batch size değerleri doğrulama F1-score üzerinde anlamlı bir iyileşme sağlamamıştır. Bu nedenle hem ana eğitim hem de fine-tuning aşamalarında batch size 32 kullanılmıştır.

Elde Edilen Optimum Parametreler: Model olarak EfficientNet-B0 kullanılmış, optimizer olarak Adam tercih edilmiştir. Kayıp fonksiyonu sınıf ağırlıklı Cross Entropy Loss olarak belirlenmiştir. Transfer learning aşamasında öğrenme oranı $1e-4$, fine-tuning aşamasında ise $1e-5$ olarak uygulanmıştır. Batch size değeri 32 olarak seçilmiştir. Transfer learning süreci 15 epoch boyunca sürdürülmiş ve doğrulama seti üzerindeki en yüksek performansa 15. epoch'ta ulaşılmıştır. Fine-tuning süreci 5 epoch boyunca gerçekleştirilmiştir. Ana değerlendirme metriği olarak macro F1-score kullanılmıştır.

Sonuç: Seçilen EfficientNet-B0 mimarisi, düşük parametre sayısına rağmen yüksek genellemeye başarımı göstermiştir.

5.2. Model 2: ResNet18 / Xception (Geliştirici: Zeynep Ekinci)

a) ResNet18

Mimari Seçimi: Vize aşamasında kullanılan temel CNN mimarisi yerine, residual bağlantılar sayesinde derin ağların etkin biçimde eğitilmesini sağlayan ResNet18 mimarisi tercih edilmiştir. ResNet18, daha az katmana sahip olmasına rağmen residual (skip) bağlantıları sayesinde gradyan kaybı (vanishing gradient) problemini azaltmaka ve sınırlı veri koşullarında daha kararlı bir öğrenme süreci sunmaktadır. Bu özellik, HAM10000 gibi sınıf dengesizliği bulunan tıbbi görüntü veri setlerinde genellemeye performansını artırmaktadır.

Teknik: Model eğitiminde ImageNet veri seti üzerinde önceden eğitilmiş ResNet18 ağırlıkları kullanılmıştır. Çıkış katmanında yer alan Fully Connected (FC) katman, problem gereği 7 sınıfı olacak şekilde yeniden yapılandırılmıştır.

Eğitim süreci iki aşamalı olarak yürütülmüştür:

- İlk aşamada yalnızca sınıflandırıcı katman eğitilmiş (transfer learning),
- İkinci aşamada tüm ağ katmanları öğrenilebilir hale getirilerek düşük öğrenme oranı ile fine-tuning uygulanmıştır.

Bu yaklaşım, modelin hem genel görsel özellikleri korumasını hem de cilt lezyonlarına özgü detayları daha iyi öğrenmesini sağlamıştır.

Hyperparameter Tuning: Model performansını optimize etmek amacıyla manuel hiperparametre denemeleri gerçekleştirilmiştir. Öğrenme oranı, epoch sayısı ve dropout oranı farklı kombinasyonlar halinde test edilerek doğruluk ve F1-score metrikleri üzerinden değerlendirme yapılmıştır.

Yöntem: Eğitim süreci, önce transfer learning ardından fine-tuning olacak şekilde planlanmıştır. Fine-tuning aşamasında öğrenme oranı düşürülerek ağırlık güncellemlerinin daha hassas yapılması sağlanmıştır. Bu strateji, overfitting riskini azaltırken modelin zor sınıflardaki performansını artırmıştır.

Optimizer: Eğitim sırasında Adam optimizasyon algoritması kullanılmıştır. Adam'ın adaptif öğrenme oranı yapısı, ResNet18 gibi orta derinlikteki ağlarda stabil ve hızlı bir yakınsama sağlamıştır.

Learning Rate: Transfer learning aşamasında daha yüksek bir öğrenme oranı kullanılırken, fine-tuning aşamasında öğrenme oranı azaltılmıştır. Bu sayede önceden öğrenilmiş ağırlıkların bozulması engellenmiştir.

Batch Size: Eğitim sürecinde bellek kullanımı ve gradyan stabilitesi göz önünde bulundurularak batch size değeri 32 olarak belirlenmiştir.

Loss Fonksiyonu: Çok sınıfı yapı nedeniyle CrossEntropyLoss kullanılmıştır. Bu fonksiyon, sınıflar arası ayırm gücünü artırarak modelin genel performansını iyileştirmiştir.

Elde Edilen Optimum Parametreler

- Mimari: ResNet18
- Epoch: 15
- Batch Size: 32
- Optimizer: Adam
- Loss: CrossEntropyLoss
- Dropout: 0.5

Sonuç: ResNet18 mimarisi, düşük hesaplama maliyeti ve stabil öğrenme yapısı sayesinde cilt lezyonlarının sınıflandırılmasında dengeli bir performans sergilemiştir. Model, özellikle sınırlı veri koşullarında makul doğruluk ve F1-score değerleri elde ederek, daha derin mimariler için güçlü bir referans modeli olarak değerlendirilmiştir.

b) Xception

Uyarı / Açıklama: Xception modeli, derinlik-ayrılabilir konvolüsyon yapısı nedeniyle klasik CNN ve ResNet tabanlı mimarilerden farklı bir yaklaşım sunmaktadır. Bu model, transfer learning ve kısmi fine-tuning stratejileriyle eğitilmiş; nihai sonuçlar, en iyi performansın alındığı yapı üzerinden raporlanmıştır.

Mimari Seçimi: Xception mimarisi, depthwise separable convolution yapısı sayesinde daha az parametre kullanarak yüksek seviyede özellik çıkarımı yapabilmektedir. Bu mimari, özellikle cilt lezyonlarında görülen ince doku, renk ve sınır farklılıklarının öğrenilmesinde etkili bir yapı sunmaktadır. Parametre verimliliği sayesinde overfitting riski azaltılmış ve modelin genelleme yeteneği artırılmıştır.

Teknik: ImageNet veri seti üzerinde önceden eğitilmiş Xception modeli kullanılmış ve sınıflandırıcı katman 7 sınıfa uyarlanmıştır. Eğitim süreci aşamalı olarak yürütülmüştür:

- İlk 10 epoch boyunca yalnızca Fully Connected (FC) katman eğitilmiştir.
- Ardından Exit Flow (block11–block12) ve FC katmanı açılarak fine-tuning uygulanmıştır.

Bu kademeli yaklaşım, modelin alt seviyedeki genel özelliklerini koruyarak üst düzey cilt lezyonuna özgü özellikleri daha iyi öğrenmesini sağlamıştır.

Hyperparameter Tuning: Hiperparametre optimizasyonu manuel deneme yöntemiyle gerçekleştirilmiştir. Öğrenme oranı, batch size ve dropout oranları farklı kombinasyonlarda test edilerek modelin doğruluk ve F1-score performansı gözlemlenmiştir.

Yöntem: Transfer learning aşamasının ardından, yalnızca Exit Flow katmanlarının açılmasıyla kısmi fine-tuning uygulanmıştır. Bu yöntem, tüm ağın yeniden eğitilmesine kıyasla daha kontrollü bir öğrenme süreci sunmuş ve overfitting riskini azaltmıştır.

Optimizer: Eğitim sürecinde Adam optimizasyon algoritması kullanılmıştır. Adam, Xception mimarisinin karmaşık katman yapısında stabil bir optimizasyon süreci sağlamıştır.

Learning Rate: Fine-tuning aşamasında öğrenme oranı düşürülmektedir. Bu sayede önceden öğrenilmiş temsiller korunmuştur.

Batch Size: Xception mimarisinin bellek gereksinimleri göz önünde bulundurularak batch size değeri 16 olarak belirlenmiştir.

Loss Fonksiyonu: Çok sınıfı sınıflandırma problemi için CrossEntropyLoss kullanılmıştır.

Elde Edilen Optimum Parametreler

- Mimari: Xception
- Epoch: 15
- Batch Size: 16
- Optimizer: Adam
- Loss: CrossEntropyLoss
- Dropout: 0.5

Sonuç: Xception mimarisi, parametre verimliliği ve güçlü özellik çıkarım yeteneği sayesinde özellikle zor sınıflarda başarılı sonuçlar üretmiştir. Model, cilt lezyonlarının sınıflandırılmasında ince detayları ayırt edebilme kabiliyeti ile klinik karar destek sistemleri için umut verici bir performans sergilemiştir.

5.3. Model 3 (SafakCNN): ResNet34 / EfficientNet-B3 (Geliştirici: Zeynep Şafak)

a) ResNet34

- **Mimari Seçimi:** Bu çalışmada temel mimari olarak, derin öğrenme alanında başarımı kanıtlanmış olan ResNet34 modeli tercih edilmiştir. ResNet mimarisi, derin ağlarda karşılaşılan vanishing gradient problemini artık (residual) bağlantılar sayesinde etkili biçimde azaltmaktadır ve daha derin ağların kararlı şekilde eğitilmesine olanak tanımaktadır. HAM10000 veri setinin sınıf dengesizliği ve dermatolojik lezyonların yüksek görsel benzerliği göz önüne alındığında, önceden ImageNet veri seti üzerinde eğitilmiş bir modelin kullanılması, düşük seviyeli ve ayırt edici özelliklerin daha hızlı ve güvenilir

şekilde öğrenilmesini sağlamıştır. Bu nedenle sıfırdan eğitilen BaseCNN modeli yerine, daha yüksek genelleme kabiliyetine sahip ResNet34 mimarisi kullanılmıştır.

- **Teknik:** Model eğitimi transfer learning ve iki aşamalı eğitim stratejisi ile gerçekleştirilmiştir. İlk aşamada, önceden eğitilmiş ResNet34 modelinin tüm katmanları dondurulmuş, yalnızca son Fully Connected (FC) katman eğitilmiştir. Bu yaklaşım, modelin genel görsel özelliklerini koruyarak veri setine hızlı adaptasyon sağlamaşını amaçlamaktadır. İkinci aşamada ise, modelin tüm katmanları açılarak full fine-tuning uygulanmış ve düşük öğrenme oranı ile ağın tamamının veri setine daha hassas biçimde uyum sağlamaşı hedeflenmiştir. Eğitim sürecinde data augmentation, early stopping ve validation tabanlı model seçimi teknikleri kullanılarak aşırı öğrenmenin önüne geçilmiştir.
- **Hyperparameter Tuning:** Bu çalışmada manuel (deneysel) hyperparameter tuning yöntemi kullanılmıştır. Grid Search veya Random Search gibi otomatik yöntemler yerine, literatürde yaygın olarak önerilen başlangıç değerleri temel alınmış ve doğrulama seti performansına göre parametreler kademeli olarak optimize edilmiştir. Özellikle learning rate, eğitim aşamaları (FC / fine-tuning), epoch sayısı ve early stopping patience değerleri üzerinde durulmuştur. Her parametre kombinasyonu, validation accuracy ve validation loss değerleri izlenerek değerlendirilmiş; aynı zamanda klinik açıdan kritik olan kanser kaçırma oranı (False Negative Rate) de model seçimi sürecine dahil edilmiştir.
- **Elde Edilen Optimum Parametreler:** Modelin giriş görüntü boyutu 224×224 olarak belirlenmiş ve eğitim sürecinde batch size 32 seçilmiştir. Optimizasyon için Adam optimizer tercih edilmiş; iki aşamalı eğitim stratejisi kapsamında, yalnızca Fully Connected (FC) katmanın eğitildiği ilk aşamada öğrenme oranı $1e-3$, tüm ağın açıldığı full fine-tuning aşamasında ise daha kararlı bir güncelleme sağlamak amacıyla $1e-4$ olarak ayarlanmıştır. Kayıp fonksiyonu olarak çok sınıflı sınıflandırma problemleri için uygun olan CrossEntropyLoss kullanılmıştır. Eğitim süresi her iki aşama için de en fazla 10 epoch ile sınırlanmış ve doğrulama performansına bağlı olarak patience değeri 3 olan early stopping mekanizması uygulanmıştır. Aşırı öğrenmenin önüne geçmek ve modelin genelleme yeteneğini artırmak amacıyla veri artırma kapsamında rastgele yatay çevirme (Random Horizontal Flip), ± 10 derece rastgele döndürme (Random Rotation) ve normalize etme işlemleri uygulanmıştır.

b) EfficientNet-B3

- **Mimari Seçimi:** Bu çalışmada temel mimari olarak, yüksek doğruluk-parametre verimliliği dengesi sunan EfficientNet-B3 modeli tercih edilmiştir. EfficientNet mimarisi, ağ derinliği, genişliği ve giriş çözünürlüğünü birlikte ölçeklendiren compound scaling yaklaşımı sayesinde, klasik CNN ve ResNet tabanlı modellere kıyasla daha az parametre ile daha güçlü temsil yeteneği sağlamaktadır. Dermatolojik lezyonların ince doku detayları ve sınıflar arası görsel benzerliği dikkate alındığında, EfficientNet-B3'ün daha yüksek çözünürlükte (300×300) çalışabilmesi ve detayları daha iyi yakalayabilmesi, HAM10000 veri seti için uygun bir tercih olmuştur. Ayrıca modelin ImageNet üzerinde önceden eğitilmiş olması, düşük seviyeli görsel özelliklerin etkin biçimde aktarılmasına olanak tanımıştır.
- **Teknik:** Model eğitimi transfer learning ve iki aşamalı eğitim (fine-tuning) stratejisi ile gerçekleştirilmiştir. İlk aşamada EfficientNet-B3 modelinin önceden eğitilmiş ağırlıkları korunmuş, yalnızca sınıflandırma katmanı (classifier) HAM10000 veri setine uygun olacak şekilde yeniden tanımlanmıştır. Bu aşamada model, genel görsel özelliklerini bozmadan veri setine hızlı adaptasyon

sağlamıştır. İkinci aşamada ise modelin feature extraction katmanlarının gradient'leri açılarak tüm ağ üzerinde full fine-tuning uygulanmış ve daha düşük öğrenme oranı kullanılarak modelin dermatolojik lezyonlara özgü ince detayları öğrenmesi hedeflenmiştir. Eğitim sürecinde data augmentation, early stopping ve doğrulama seti tabanlı model seçimi kullanılarak aşırı öğrenme engellenmiştir.

- **Hyperparameter Tuning:** Bu çalışmada hyperparameter ayarları manuel (deneysel) tuning yöntemiyle belirlenmiştir. Literatürde EfficientNet mimarileri için önerilen başlangıç değerleri esas alınmış; öğrenme oranı, batch size, epoch sayısı ve early stopping parametreleri doğrulama seti performansına göre kademeli olarak optimize edilmiştir. Özellikle learning rate, EfficientNet mimarisinin hassas yapısı nedeniyle kritik bir parametre olarak ele alınmış; fine-tuning aşamasında daha düşük öğrenme oranları denenmiştir. Model seçimi sürecinde yalnızca doğruluk (accuracy) değil, aynı zamanda klinik açıdan kritik olan kanser kaçırma oranı (False Negative Rate) da değerlendirme kriteri olarak kullanılmıştır.
- **Elde Edilen Optimum Parametreler:** Modelin giriş görüntü boyutu 300×300 olarak belirlenmiş ve eğitim sürecinde batch size 16 tercih edilmiştir. Optimizasyon yöntemi olarak adaptif öğrenme oranı sayesinde kararlı ve hızlı yakınsama sağlayan Adam optimizatoru kullanılmıştır. Eğitim iki aşamalı olarak yürütülmüştür: ilk aşamada model, $1e-4$ öğrenme oranı ile eğitilmiş; ikinci aşamada ise tüm ağ katmanlarının açıldığı full fine-tuning sürecinde daha hassas ağırlık güncellemleri yapabilmek amacıyla öğrenme oranı $1e-5$ seviyesine düşürülmüştür. Kayıp fonksiyonu olarak çok sınıflı sınıflandırma problemleri için yaygın ve etkili bir yöntem olan CrossEntropyLoss kullanılmıştır. İlk eğitim aşaması en fazla 15 epoch, fine-tuning aşaması ise en fazla 5 epoch ile sınırlanmıştır; doğrulama doğruluğunda iyileşme gözlenmediği durumlarda eğitimi erken sonlandırmak için patience değeri 5 olan early stopping mekanizması uygulanmıştır. Modelin aşırı öğrenmesini azaltmak ve genelleme performansını artırmak amacıyla veri artırma kapsamında rastgele yatay çevirme (Random Horizontal Flip), ± 15 derece rastgele döndürme (Random Rotation) ve normalize etme işlemleri kullanılmıştır.

5.4. Model 4 (BaseCNN): EfficientNet-B1 / DenseNet-121 (Geliştirici: Miyase Eda Erol)

a) EfficientNet-B1

- **Mimari Seçimi:** Bu çalışmada iki aşamalı bir yaklaşım izlenmiştir. İlk olarak, referans oluşturmak amacıyla basit yapılı BaseCNN modeli kullanılmıştır. Ardından daha güçlü temsil kabiliyeti ve literatürdeki başarısı nedeniyle EfficientNet-B1 mimarisi tercih edilmiştir. ImageNet ön-eğitimli ağırlıklar kullanılarak transfer öğrenme uygulanmış, son sınıflandırma katmanı HAM10000 veri setine uygun olacak şekilde 7 sınıfa uyarlanmıştır. Fine-tuning ile tüm katmanlar öğrenmeye açılarak modelin veri setine adaptasyonu artırılmıştır.
- **Teknik:** Veri seti, sınıf dengesini korumak amacıyla Stratified K-Fold ve stratified validation yöntemleri ile bölünmüştür. Eğitim sırasında veri artırma (flip, rotation) uygulanmış, aşırı öğrenmeyi önlemek için Early Stopping kullanılmıştır. Model performansı; accuracy, confusion matrix, precision-recall, ROC-AUC ve özellikle klinik açıdan kritik olan False Negative Rate metrikleri ile değerlendirilmiştir. Ayrıca Grad-CAM ile model kararları görsel olarak yorumlanmıştır.

- **Hyperparameter Tuning:** Öğrenme oranı, epoch sayısı ve fine-tuning stratejileri deneysel olarak ayarlanmıştır. İlk aşamada düşük learning rate ile eğitim yapılmış, fine-tuning aşamasında feature ve classifier katmanları için farklı öğrenme oranları kullanılmıştır. Validation loss takibi ile en iyi model seçilmiştir.
- **Elde Edilen Optimum Parametreler:** Modelin giriş boyutu 128×128 olarak belirlenmiş ve eğitim sürecinde batch size 32 seçilmiştir. Optimizasyon yöntemi olarak Adam optimizer tercih edilmiştir. Fine-tuning aşamasında, ağıın feature katmanları için öğrenme oranı $1e-4$, sınıflandırıcı (classifier) katmanı için ise $1e-3$ olarak ayarlanmıştır. Kayıp fonksiyonu olarak CrossEntropyLoss kullanılmış, eğitim süreci en fazla 10 epoch ile sınırlanmıştır. Aşırı öğrenmeyi önlemek amacıyla early stopping uygulanmış ve doğrulama kaybının 5 epoch boyunca iyileşmemesi durumunda eğitim sonlandırılmıştır.

b) DenseNet-121

- **Mimari Seçimi:** Bu projede, temel bir referans mimari olarak BaseCNN kullanılmış, ardından bu yapının geliştirilmiş ve optimize edilmiş bir versiyonu olarak EfficientNet-B1 tercih edilmiştir. EfficientNet-B1, BaseCNN'e kıyasla daha derin ve dengeli ölçeklendirilmiş yapısı sayesinde daha yüksek özellik çıkarım kapasitesi sunmaktadır. ImageNet üzerinde önceden eğitilmiş ağırlıklar ile transfer öğrenme uygulanmış ve modelin son sınıflandırma katmanı, veri setindeki 7 sınıfına uygun olacak şekilde yeniden yapılandırılmıştır.
- **Teknik:** Model eğitiminde transfer öğrenme yaklaşımı kullanılmış, ImageNet üzerinde önceden eğitilmiş ağırlıklar başlangıç noktası olarak alınmıştır. Eğitim sürecinde veri artırma teknikleri (rastgele döndürme ve yatay çevirme) ile modelin genelleme yeteneği artırılmıştır. Sınıf dengesizliğini azaltmak amacıyla ağırlıklı CrossEntropyLoss kullanılmış, optimizasyon için Adam algoritması tercih edilmiştir. Eğitim sırasında ReduceLROnPlateau öğrenme oranı zamanlayıcısı ve Early Stopping mekanizması uygulanarak aşırı öğrenmenin önüne geçilmiştir.
- **Hyperparameter Tuning:** Model performansını artırmak amacıyla öğrenme oranı, batch size, epoch sayısı ve optimizer parametreleri deneysel olarak ayarlanmıştır. Özellikle önceden eğitilmiş özellik çıkarım katmanları ile sınıflandırıcı katmanı için farklı öğrenme oranları denenmiş, doğrulama kaybını minimize eden değerler tercih edilmiştir. Erken durdurma ve öğrenme oranı düşürme stratejileri, aşırı öğrenmeyi engellemek amacıyla tuning sürecine dahil edilmiştir.
- **Elde Edilen Optimum Parametreler:** Yapılan testler sonucunda en iyi performans; giriş görüntünün 128×128 , batch size değerinin 32, optimizer olarak Adam kullanılması ve maksimum 10 epoch eğitim ile elde edilmiştir. Özellik çıkarım katmanları için öğrenme oranı $1e-4$, sınıfandrıcı katmanı için ise $1e-3$ olarak belirlenmiştir. Kayıp fonksiyonu olarak CrossEntropyLoss, erken durdurma için patience=5 değeri kullanılmıştır.

5.5. Model 5 EfficientNet-B0 / ResNet101 (Geliştirici: Eylül Erdemci)

a) EfficientNet-B0

Mimari Seçimi: Bu çalışmada, vize aşamasında kullanılan temel CNN mimarilerinin sınırlamalarını aşmak amacıyla, daha az parametre ile yüksek doğruluk sunan EfficientNet-B0 mimarisi tercih edilmiştir. EfficientNet, derinlik, genişlik ve giriş çözünürlüğünü dengeli biçimde ölçeklendiren compound scaling yaklaşımı sayesinde, medikal görüntü sınıflandırma problemlerinde yüksek performans sağlamaktadır. Bu özellikleri nedeniyle EfficientNet-B0, dermatoskopik cilt lezyonlarının sınıflandırılması için uygun bir mimarı olarak seçilmiştir.

Teknik: Bu modelde, ImageNet veri seti üzerinde önceden eğitilmiş (pre-trained) EfficientNet-B0 ağırlıkları kullanılmıştır. Transfer learning yaklaşımı benimsenerek, modelin son sınıflandırıcı (Fully Connected) katmanı çıkarılmış ve HAM10000 veri setine uygun olacak şekilde 7 sınıfı yeni bir çıktı katmanı eklenmiştir. Eğitim sürecinin ilk aşamasında EfficientNet-B0 modelinin özellik çıkarıcı (feature extractor) katmanları dondurulmuş, yalnızca sınıflandırıcı katman eğitilmiştir. İkinci aşamada ise tüm katmanlar açılarak düşük öğrenme oranı ile fine-tuning uygulanmış ve modelin dermatolojik özelliklere daha iyi adapte olması sağlanmıştır.

Hyperparameter Tuning: Model eğitimi sırasında hiperparametreler manuel deneme yöntemi ile optimize edilmiştir; Optimizer olarak Adam, Learning Rate 0.0001, Batch Size 32, Loss Fonksiyonu CrossEntropyLoss ve Epoch Sayısı 10 olarak belirlenmiştir. Epoch sayısı, overfitting riskini azaltmak ve eğitim süresini optimize etmek amacıyla sınırlı tutulmuştur.

b) ResNet101

Mimari Seçimi: EfficientNet-B0 modeline ek olarak, daha derin bir mimari olan ResNet101 kullanılarak performans karşılaştırması yapılmıştır. ResNet101, artık bağlantılar (residual connections) sayesinde derin ağlarda karşılaşılan gradyan kaybolması problemini azaltmakta ve daha karmaşık özelliklerin öğrenilmesine olanak tanımaktadır. Bu özellikleri nedeniyle ResNet101, cilt lezyonlarının sınıflandırılmasında güçlü bir alternatif model olarak değerlendirilmiştir.

Teknik: Bu çalışmada ResNet101 modeli pretrained ağırlıklar kullanılmadan sıfırdan eğitilmiştir. Modelin orijinal son tam bağlı (Fully Connected) katmanı kaldırılmış ve yerine HAM10000 veri setine uygun 7 sınıfı yeni bir çıktı katmanı eklenmiştir. Eğitim sürecinde tüm ağ katmanları optimize edilerek modelin dermatoskopik görüntülere özgü özelliklerini doğrudan öğrenmesi hedeflenmiştir.

Hyperparameter Tuning: ResNet101 modeli için kullanılan hiperparametreler: Optimizer olarak Adam, öğrenme oranı (Learning Rate) 0.0001, Batch Size 32, Loss Fonksiyonu CrossEntropyLoss ve Epoch sayısı 10 olarak belirlenmiştir. Derin mimarinin aşırı öğrenmeye (overfitting) gitmesini engellemek amacıyla epoch sayısı kontrollü tutulmuştur.

6) Grad-CAM'ın Çalışma Mekanizması ve Modellerle İlişkisi

1. Amaç:

- Grad-CAM (Gradient-weighted Class Activation Mapping), derin öğrenme modellerinin **hangi bölgeleri sınıf tahmininde daha fazla kullandığını görselleştirmek** için kullanılan bir tekniktir. Yani modelin kararını “görsel olarak açıklamak” için kullanılır.

2. Modelden bilgi alma:

- Grad-CAM, sınıflandırma modelinin **son evrişimsel (convolutional) katmanı** üzerinde çalışır.
- Bu katmandaki aktivasyon haritaları, modelin görüntüde “özellikleri” nasıl yakaladığını gösterir.
- Ayrıca, seçilen sınıfın ait **gradyanlar** (loss'a göre türevler) hesaplanır. Bu gradyanlar, hangi özelliklerin sınıf tahmininde daha önemli olduğunu belirtir.

3. Çalışma adımları:

İleri yönlü geçiş (Forward Pass):

- Model, giriş görüntüsünü işleyerek sınıf tahminini yapar. Son conv katmanındaki aktivasyonlar kaydedilir.

Geri yönlü geçiş (Backward Pass):

- Tahmin edilen veya seçilen sınıf için loss hesaplanır ve geri yayılım yapılır. Bu sırada, son conv katmanındaki aktivasyonlar için gradyanlar tutulur.

Ağırlıklı aktivasyon haritası:

- Her feature map'in (aktivasyon kanalının) sınıf tahminine katkısı, o kanaldaki gradyanın ortalaması alınarak hesaplanır.
- Bu ağırlıklar, aktivasyon haritalarıyla çarpılır ve kanallar toplanır. Böylece **sınıfa duyarlı bir 2D harita** elde edilir.

ReLU ve normalize etme:

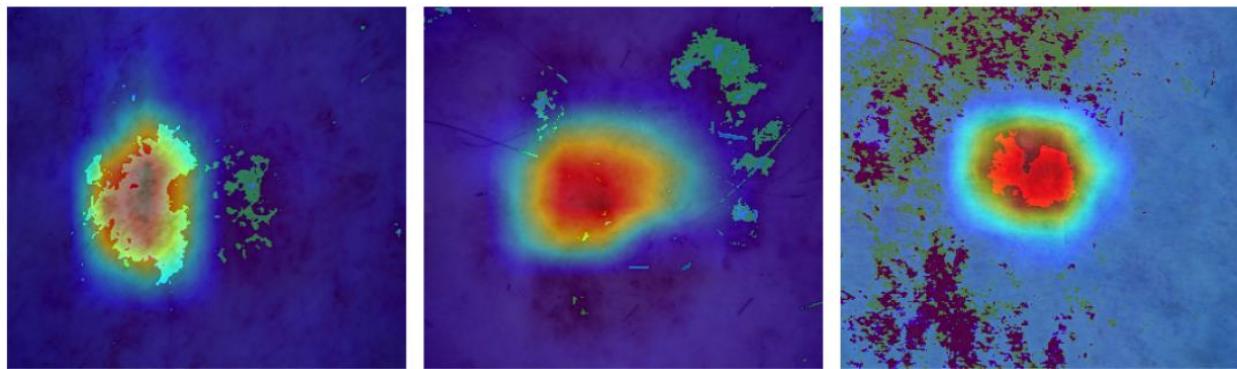
- Negatif değerler sıfırlanır (çünkü modelin sınıfı olumsuz katkıları görselde göstermeye gerek yok).
- Harita 0–1 aralığına normalize edilir ve giriş görüntüsüne bindirilir (overlay).

4. Karar verme mekanizması:

- Grad-CAM doğrudan sınıf tahmini yapmaz; model zaten tahmini yapmıştır.
- Grad-CAM, modelin bu tahmine **hangi görsel bölgelere bakarak ulaştığını** gösterir.
- Örneğin, “Cancer” tahmininde Grad-CAM, modelin dikkatini **lezyon veya anormal dokulara verdiğini** görselleştirir.

5. Özette:

Grad-CAM, modelin son conv katmanındaki özellik haritalarını ve sınıf gradyanlarını kullanarak, modelin sınıf kararını hangi bölgeler üzerinden verdiğiğini görselleştirir. Bu, modelin karar mekanizmasını açıklamak ve güvenilirliğini değerlendirmek için kullanılır.



7) Deney Tasarımı

Amaç ve Kapsam: Bu çalışmanın temel amacı, HAM10000 veri setindeki dermatoskopik cilt lezyonlarını sınıflandırmada en yüksek başarıyı sağlayan Derin Öğrenme mimarisini tespit etmektir. Vize aşamasında geliştirilen sıç (shallow) CNN modellerinin performans sınırlarını aşmak amacıyla, Final aşamasında **Transfer Öğrenme (Transfer Learning)** ve **İnce Ayar (Fine-Tuning)** stratejileri benimsenmiştir.

Model Hiyerarşisi: Deneyler iki ana aşamada kurgulanmıştır:

1. **Baseline (Taban) Modeller:** Özel tasarlanmış sıç CNN mimarileri (SkinClassifierBase, SafakCNN vb.).
2. **Gelişmiş Modeller:** ImageNet üzerinde ön eğitimli (pre-trained) ağırlıklara sahip **ResNet50**, **EfficientNet-B0**, **ResNet18** vb. mimarileri. Bu modellerin son katmanları 7 sınıfı çıktı verecek şekilde modifiye edilmiş ve HAM10000 veri setine uyarlanmıştır.

Eğitim Stratejisi ve Hiperparametre Optimizasyonu: Tüm modeller PyTorch çatısı altında eğitilmiştir. Veri seti, sınıf dengesizliğini gözetmek adına StratifiedKFold veya stratifikasyonlu ayırma yöntemiyle **Eğitim (%70), Doğrulama (%15) ve Test (%15)** setlerine bölünmüştür.

- **Optimizasyon:** Modellerin eğitiminde **Adam** ve **AdamW** optimizatörleri kullanılmıştır.
- **Hiperparametre Ayarlama (Tuning):** Her grup üyesi kendi modeli için Learning Rate (Örn: 1e-3, 1e-4), Batch Size (16, 32, 64) ve Dropout oranlarını (0.3 - 0.5) deneyel olarak optimize etmiştir.
- **Loss Fonksiyonu:** Sınıf dengesizliğinin (Örn: MEL sınıfının azlığı) model başarısını düşürmesini engellemek için standart Cross-Entropy Loss yerine **Weighted Cross-Entropy Loss** kullanılarak azınlık sınıflara daha fazla ceza puanı atanmıştır.
- **Schedulers:** Eğitim sırasında loss değerinin platoya girmesi durumunda ReduceLROnPlateau kullanılarak öğrenme oranı dinamik olarak düşürülmüştür.

Değerlendirme Metrikleri: Nihai performans karşılaştırması için **Test Seti** kullanılmıştır. Sınıf dengesizliği nedeniyle sadece Doğruluk (Accuracy) metriği yaniltıcı olabileceğinden, **Weighted F1-Score**, **Precision**, **Recall** ve **ROC-AUC** metrikleri ana başarı kriteri olarak belirlenmiştir. Final raporunun sonuç bölümünde tüm bu modellerin performansları karşılaştırmalı tablolarla sunulmuştur.

8) Kullanılan Araçlar ve Frameworkler

Bu projenin uça geliştirilmesinde, derin öğrenme topluluğunda endüstri standarı olan kütüphaneler ve donanımlar kullanılmıştır:

- **Derin Öğrenme Çatısı: PyTorch** (Modelleme, eğitim döngüleri ve tensör işlemleri için).
- **Transfer Learning Modülleri:** torchvision.models kütüphanesi kullanılarak ResNet, EfficientNet ve Xception gibi önceden eğitilmiş mimariler projeye dahil edilmiştir.
- **Veri İşleme ve Görselleştirme:**
 - **Pandas & NumPy:** Veri manipülasyonu ve matris işlemleri.
 - **Scikit-learn:** Veri setinin stratifikasyonlu bölünmesi (StratifiedKFold), sınıf ağırlıklarının hesaplanması (class weights) ve performans metrikleri (confusion matrix, classification report) için.
 - **Matplotlib & Seaborn:** Eğitim kaybı (loss) grafikleri, karmaşıklık matrislerinin görselleştirilmesi ve veri dağılım analizleri için.
 - **Pillow (PIL) & Torchvision Transforms:** Görüntülerin yeniden boyutlandırılması, normalizasyonu ve veri artırma (Data Augmentation - RandomHorizontalFlip, Rotation, ColorJitter) işlemleri için.
- **Donanım ve Ortam:**
 - Eğitim süreçleri, yüksek hesaplama gücü gerektirdiği için **NVIDIA GPU** (Google Colab T4 veya yerel CUDA destekli GPU'lar) üzerinde gerçekleştirilmiştir.
- **Versiyon Kontrol:** Proje süreci, kod paylaşımı ve versiyon takibi **GitHub** üzerinden yönetilmiştir.
 - **Repo Linki:** https://github.com/iamsevval/SkinCancer_DL_Project

Performans Karşılaştırması ve Tablolar

Aşağıdaki tablolarda, eğitim sonrası **Test Verisi** üzerinde elde edilen sonuçlar karşılaştırılmıştır. En iyi değerler **kalın (bold)** font ile belirtilmiştir.

Tablo 1: Genel Model Karşılaştırması (Test Seti Ortalaması)

Model (Geliştirici)	Mimari	BalancedAccuracy	F1-Score (Macro)	Precision (Macro)	Recall (Macro)	ROC-AUC (Macro-OVR)
Model 1 (Şevval Arslan)	Efficient-B0	0.82	0.78	0.75	0.82	0.97
Model 1 (Şevval Arslan)	ResNet50	0.84	0.81	0.79	0.85	0.97
Model2 (Zeynep Ekinci)	ResNet18	0.83	0.68	0.83	0.83	0.96
Model2 (Zeynep Ekinci)	Xception	0.81	0.60	0.80	0.81	0.94
Model3(Zeynep Şafak)	ResNet-34	0.84	0.72	0.77	0.69	0.96

Model3(Zeynep Şafak)	EfficientNet-B3	0.90	0.81	0.84	0.78	0.97
Model4(Eda Erol)	EfficientNet-B1	0.86	0.76	0.78	0.74	0.96
Model4(Eda Erol)	DenseNet-121	0.80	0.77	0.74	0.83	0.95
Model5(Eylül)	ResNet101	0.67	0.11	0.10	0.14	0.9056
Model5 (Eylül)	EfficientB0	0.73	0.11	0.10	0.14	0.9235

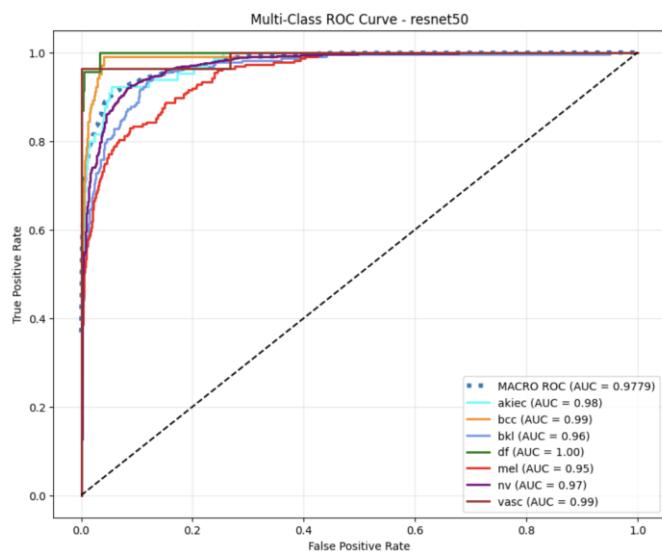
Tablo 2: Sınıf Bazlı (Class-wise) Karşılaştırması

Sınıf dengesizliği nedeniyle, modellerin özellikle azınlık sınıflardaki (Melanoma gibi) başarısı kritiktir.

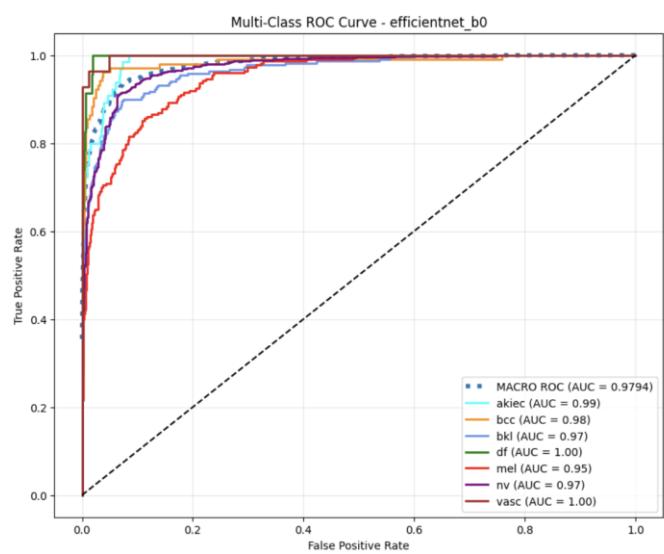
Şevel Arslan:

Efficient-B0 (Şevel Arslan)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.65	0.73	0.69	223
NV (Benign)	0.96	0.90	0.93	1341
BCC	0.75	0.85	0.80	103
AKIEC	0.71	0.75	0.73	65
BKL (Benign Keratoz)	0.71	0.82	0.76	220
VASC (Vasküler Lezyon)	0.81	0.93	0.87	28
DF (Dermatofibroma)	0.62	0.78	0.69	23

ResNet50 (Sevval Arslan)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.73	0.70	0.72	223
NV (Benign)	0.95	0.93	0.94	1341
BCC	0.70	0.89	0.79	103
AKIEC	0.65	0.78	0.71	65
BKL (Benign Keratoz)	0.75	0.74	0.74	220
VASC (Vasküler Lezyon)	0.93	0.96	0.95	28
DF (Dermatofibroma)	0.81	0.91	0.86	23



Şekil 1: ResNet50 Modeli için Sınıf Bazlı ROC Eğrisi.



Şekil 2: EfficientNet-B0 Modeli için Sınıf Bazlı ROC Eğrisi.

Zeynep Ekinci:

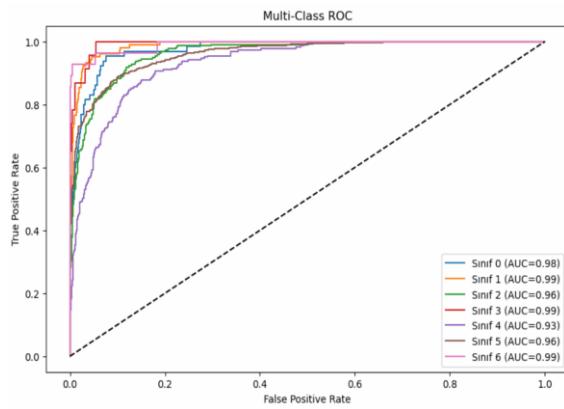
ResNet18 (Zeynep Ekinci)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.70	0.38	0.50	223
NV (Benign)	0.86	0.98	0.91	1341
BCC	0.85	0.49	0.63	103
AKIEC	0.70	0.55	0.62	65
BKL (Benign Keratoz)	0.73	0.64	0.68	220
VASC (Vasküler Lezyon)	0.77	0.81	0.79	28
DF (Dermatofibroma)	0.71	0.63	0.67	23

Xception (Zeynep Ekinci)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.71	0.40	0.51	223
NV (Benign)	0.88	0.96	0.92	1341
BCC	0.54	0.58	0.56	103
AKIEC	0.61	0.57	0.59	65
BKL (Benign Keratoz)	0.66	0.64	0.65	220
VASC (Vasküler Lezyon)	0.71	0.71	0.71	28
DF (Dermatofibroma)	0.36	0.26	0.30	23

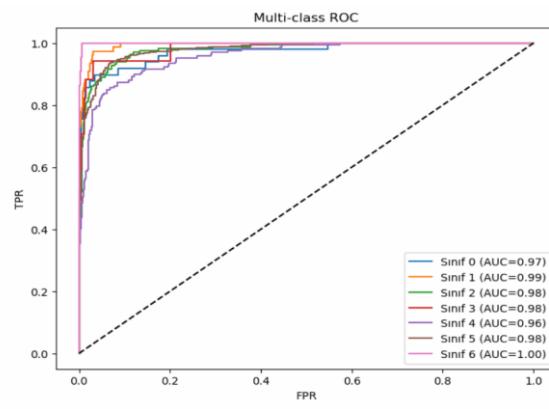
Zeynep Şafak:

ResNet-34 (Zeynep Şafak)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.66	0.54	0.60	223
NV (Benign)	0.89	0.95	0.92	1341
BCC	0.87	0.66	0.75	103
AKIEC	0.57	0.66	0.61	65
BKL (Benign Keratoz)	0.76	0.66	0.70	220
VASC (Vasküler Lezyon)	0.94	0.61	0.74	28
DF (Dermatofibroma)	0.71	0.74	0.72	23

EfficientNet-B3 (Zeynep Şafak)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.77	0.76	0.76	167
NV (Benign)	0.93	0.97	0.95	1006
BCC	0.84	0.84	0.84	77
AKIEC	0.82	0.76	0.79	49
BKL (Benign Keratoz)	0.89	0.76	0.82	165
VASC (Vasküler Lezyon)	0.90	0.86	0.88	22
DF (Dermatofibroma)	0.75	0.53	0.62	17



Şekil 1: ResNet34 Modeli için Sınıf Bazlı ROC Eğrisi.



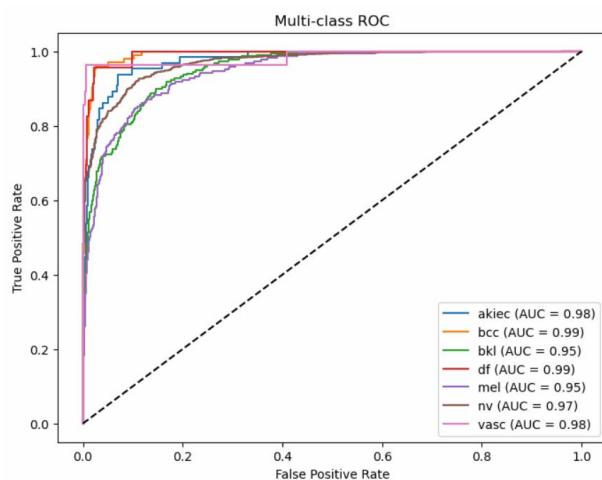
Şekil 2: EfficientNet-B3 Modeli için Sınıf Bazlı ROC Eğrisi

Miyase Eda Erol:

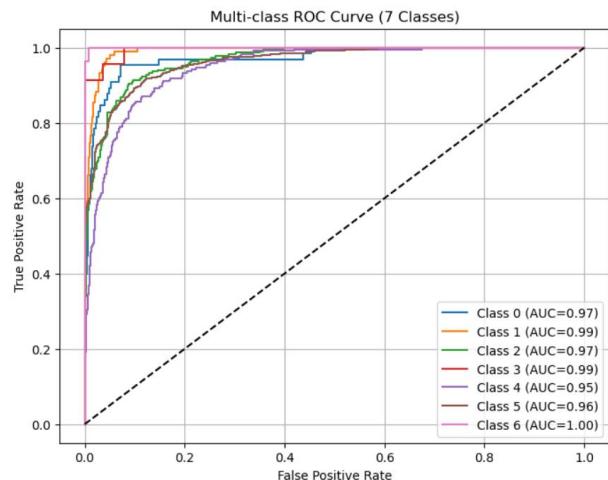
EfficientNet-B1 (Miyase Eda Erol)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.72	0.64	0.68	223
NV (Benign)	0.92	0.95	0.93	1341
BCC	0.82	0.77	0.79	103
AKIEC	0.67	0.68	0.67	65
BKL (Benign Keratoz)	0.70	0.70	0.70	220
VASC (Vasküler Lezyon)	0.92	0.82	0.87	28
DF (Dermatofibroma)	0.68	0.65	0.67	23

DenseNet-121 (Miyase Eda Erol)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.47	0.87	0.61	223
NV (Benign)	0.97	0.80	0.88	1341
BCC	0.71	0.86	0.78	103

AKIEC	0.64	0.65	0.64	65
BKL (Benign Keratoz)	0.71	0.75	0.73	220
VASC (Vasküler Lezyon)	0.79	0.96	0.87	28
DF (Dermatofibroma)	0.91	0.91	0.91	23



Şekil 1: EfficientNet-B1 Modeli için Sınıf Bazlı ROC Eğrisi.



Şekil 1: DenseNet-121 Modeli için Sınıf Bazlı ROC Eğrisi.

Eylül Erdemci:

Res-Net101 (Eylül Erdemci)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.00	0.00	0.00	167
NV (Benign)	0.67	1.00	0.80	1006
BCC	0.00	0.00	0.00	77
AKIEC	0.00	0.72	0.00	49
BKL(BenignKeratoz)	0.00	0.00	0.00	165
VASC (Vasküler Lezyon)	0.00	0.65	0.45	22
DF(Dermatofibroma)	0.00	0.00	0.00	17

Efficient-B0 (Eylül Erdemci)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.00	0.00	0.00	167
NV (Benign)	0.67	1.00	0.80	1006
BCC	0.00	0.00	0.00	77
AKIEC	0.00	0.00	0.00	49
BKL (Benign Keratoz)	0.00	0.00	0.00	165
VASC (Vasküler Lezyon)	0.00	0.00	0.00	22
DF (Dermatofibroma)	0.00	0.00	0.00	17

10) Sonuç ve Yorum

Deneysel değerlendirmeler sonucunda, HAM10000 veri seti üzerinde test edilen modellerin performansları karşılaştırılmıştır. Genel doğruluk (Accuracy) ve Weighted F1-Score değerleri göz önüne alındığında, EfficientNet-B3 modeli öne çıkmaktadır.

- Genel Performans:** EfficientNet-B3, test veri setinde yaklaşık %90 doğruluk ve %90 Weighted F1-Score ile diğer tüm modellerden daha yüksek ve dengeli bir performans göstermiştir. Bunun yanında ROC-AUC değeri de 0.97 ile yüksek, bu da modelin sınıflar arasında güçlü ayırt edici yeteneğe sahip olduğunu doğrulamaktadır.
- Sınıf Bazlı Performans:** Azınlık sınıflar (Melanoma, AKIEC, DF) açısından bakıldığından, EfficientNet-B3'ün F1-skorları diğer modellerle kıyaslandığında özellikle malign ve pre-kanser sınıflarında daha yüksek değerler sunmaktadır. Bu, sınıf dengesizliğine karşı modelin duyarlığınıın yüksek olduğunu ve klinik açıdan kritik sınıfları doğru tanıyalabileceğini göstermektedir.
- Diğer Modellerin Karşılaştırması:** EfficientNet-B0 ve ResNet50 gibi modeller genel doğrulukta yüksek skorlar almasına rağmen, sınıf bazlı F1-skorlarında özellikle nadir sınıflarda performans düşüklüğü göstermiştir. Bu durum, sadece Accuracy'ye dayalı model seçimlerinin yanıltıcı olabileceğini ortaya koymaktadır.
- Klinik Uygulanabilirlik:** Weighted F1-Score, azınlık sınıfların da performansını dikkate aldığı için klinik açıdan daha güvenilir bir ölçütür. EfficientNet-B3'ün ölçeklenebilir mimarisini ve görece düşük parametre sayısı, hem eğitim maliyetini düşürmekte hem de önemli sınıfların tespitinde yüksek duyarlılık sağlamaktadır.

Yorum: Genel doğruluk tek başına bir modelin üstünlüğünü belirlemede yetersizdir; özellikle sınıf dengesizliği olan veri setlerinde Weighted F1-Score, Precision ve Recall değerlerinin birlikte değerlendirilmesi gerekmektedir. Bu çalışmada EfficientNet-B3, hem genel performans hem de kritik sınıflardaki başarı açısından en dengeli ve güvenilir model olarak öne çıkmıştır. Klinik uygulamalarda özellikle malign ve pre-kanser lezyonların tespitinde bu modelin tercih edilmesi uygun görülmektedir.

11) En İyi Model

Yapılan deneysel değerlendirmeler sonucunda, EfficientNet-B3 modeli test veri seti üzerinde elde ettiği yaklaşık %90 doğruluk (Accuracy) ve sınıf dengesizliğine karşı daha anlamlı bir ölçüt olan %90 Weighted F1-Score değerleri ile diğer aday modeller arasında en dengeli ve güvenilir performansı sergilemiştir. HAM10000 veri setinin belirgin sınıf dengesizliği içermesi nedeniyle, yalnızca doğruluk metriğine dayalı bir model seçimi yaniltıcı olabilmektedir; bu noktada Weighted F1-Score, hem precision hem recall bileşenlerini sınıf frekanslarını dikkate alarak değerlendirdiği için klinik açıdan daha temsil edici sonuçlar sunmuştur. EfficientNet-B3'ün ölçülebilir mimarisi sayesinde görece daha az parametre ile yüksek ayırt edici özellikler öğrenebilmesi, özellikle malign ve pre-kanser sınıflarının tespitinde güçlü bir performans elde edilmesini sağlamıştır. Ayrıca ROC-AUC ve Precision–Recall analizleri ile desteklenen sonuçlar, modelin yalnızca genel doğrulukta değil, klinik olarak kritik sınıflarda da tutarlı ve kararlı tahminler üretebildiğini göstermektedir. Bu nedenlerle, performans, genellenebilirlik ve klinik uygulanabilirlik kriterleri birlikte değerlendirildiğinde, çalışmanın en iyi modeli olarak EfficientNet-B3 seçilmiştir.

12) Kaynaklar

- [1] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun, “Dermatologist-level classification of skin cancer with deep neural networks,” *Nature*, vol. 542, no. 7639, pp. 115–118, Feb. 2017.
- [2] P. Tschandl, C. Rosendahl, and H. Kittler, “The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions,” *Scientific Data*, vol. 5, no. 1, p. 180161, Aug. 2018.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [4] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in *International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114.
- [5] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, “Densely Connected Convolutional Networks,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 4700–4708.
- [6] D. P. Kingma and J. Ba, “Adam: A Method for Stochastic Optimization,” *International Conference on Learning Representations (ICLR)*, 2015.

- [7] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 618–626.
- [8] A. Paszke et al., “PyTorch: An Imperative Style, High-Performance Deep Learning Library,” in *Advances in Neural Information Processing Systems 32*, Curran Associates, Inc., 2019, pp. 8024–8035.