

Dermatoskopik Cilt Lezyonları Sınıflandırması

Ders: FET312 – Derin Öğrenme

Ekip Adı: DermAI

Ekip Üyeleri:

22040301030- Şevval Arslan

23040301081-Miyase Eda Erol

23040301071-Zeynep Şafak

23040301093-Eylül Erdemci

23040301108-Zeynep Ekinci

GitHub/Repo Bağlantısı: https://github.com/iamsevval/SkinCancer_DL_Project


YouTube Video Linki: <https://youtu.be/USt4oaalS6s>

Problem ve Amaç

Mevcut Zorluk: Cilt lezyonlarının manuel olarak teşhis edilmesi, büyük ölçüde uzman deneyimine bağlı olup sınıflar arasındaki yüksek görsel benzerlikler nedeniyle zor ve hata riski yüksek bir süreçtir. Bu durum, özellikle cilt kanserinin erken teşhisi açısından önemli bir engel teşkil etmektedir.

Proje Hedefi: Bu projede, HAM10000 veri seti kullanılarak dermatoskopik görüntüler üzerinden 7 farklı cilt lezyonu türünün (MEL, NV, BCC, AKIEC, BKL, DF, VASC) otomatik olarak sınıflandırılması amaçlanmıştır.

Yöntem: Çalışmada PyTorch framework'ü kullanılarak geliştirilen sığ (shallow) CNN modelleri ile ResNet, EfficientNet, Xception ve DenseNet gibi gelişmiş transfer öğrenme tabanlı mimariler karşılaştırılmış; en yüksek sınıflandırma başarımını elde eden mimari ayrıntılı olarak analiz edilmiştir.



Veri Seti (HAM10000)

Veri Seti Kaynağı: Bu projede kullanılan veri seti, Harvard Dataverse tarafından yayınlanan ve Kaggle platformu üzerinden erişilebilen HAM10000 (Human Against Machine with 10000 Training Images) veri setidir.

Veri Seti Boyutu ve Özellikleri: HAM10000 veri seti, toplamda 10.015 adet dermatoskopik RGB görüntüden oluşmaktadır. Orijinal görüntüler, derin öğrenme modellerine uygun olacak şekilde [ör:224×224] boyutlarına yeniden ölçeklendirilmiş ve normalize edilerek model girişinde kullanılmıştır.

Veri Yapısı: Görüntülere ek olarak hasta yaşı, cinsiyeti ve lezyon konumunu içeren metadata bilgileri mevcuttur.

Link: <https://www.kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000/data>

Sınıf Dağılımı

Sınıf Dağılımı ve Etiketler: Sınıflandırma işlemi 7 farklı etiket (label) üzerinden yapılmaktadır. Veri seti doğası gereği dengesiz (imbalanced) bir yapıdadır. Sınıf dağılımı şöyledir:

NV (Melanocytic nevi): 6705 adet örnek

MEL (Melanoma): 1113 adet örnek


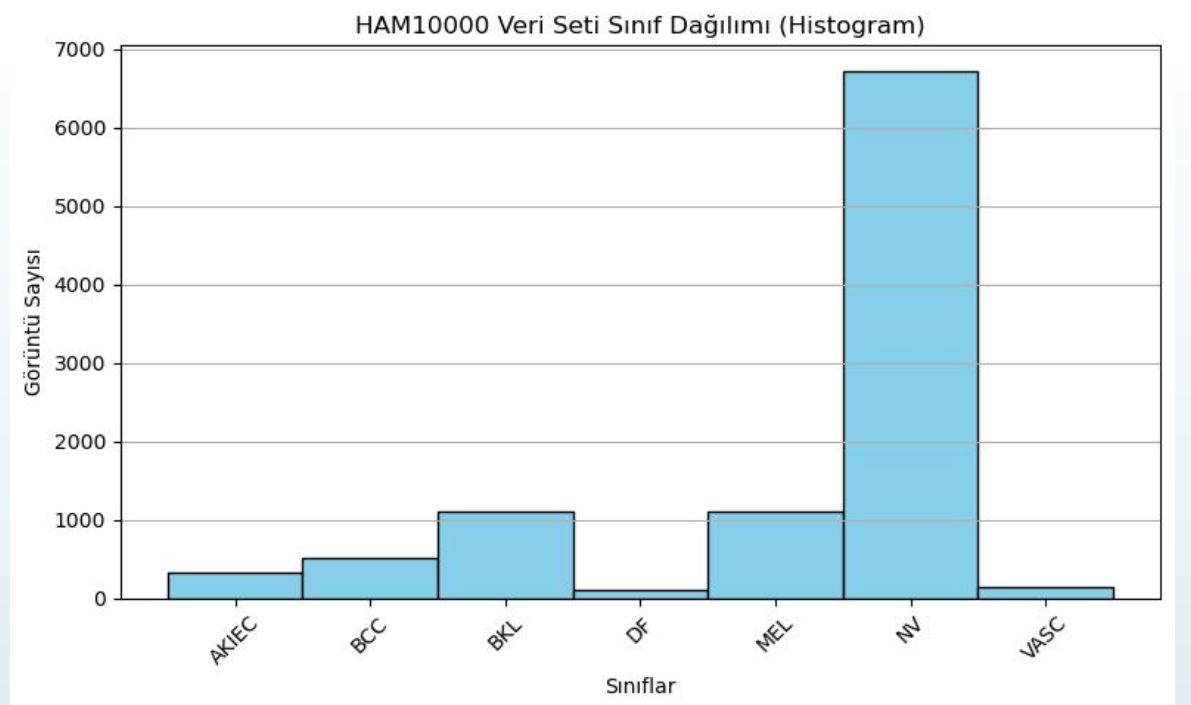
BKL (Benign keratosis): 1099 adet örnek

BCC (Basal cell carcinoma): 514 adet örnek

AKIEC (Actinic keratoses): 327 adet örnek

VASC (Vascular lesions): 142 adet örnek

DF (Dermatofibroma): 115 adet örnek



Veri Bölme

Veri Bölme Stratejisi: Projemizde rastgele bölme yerine StratifiedKFold (Katmanlı K-Fold) yöntemi tercih edilmiştir.

Neden Stratified: HAM10000 veri setinde sınıflar arasında belirgin bir dengesizlik bulunmaktadır. Özellikle NV sınıfı veri setinin yaklaşık %67'sini oluştururken, DF sınıfı yalnızca %1 civarında örnek içermektedir. Rastgele bölme kullanılması durumunda, azınlık sınıfların bazı eğitim kümelerinde hiç yer almaması söz konusu olabilmektedir. Bu durum, modelin nadir görülen lezyonları yeterince öğrenememesine ve sınıflandırma performansının düşmesine neden olabilir. Stratified yaklaşım, bu sorunu önleyerek her sınıfın tüm eğitim süreçlerinde temsil edilmesini sağlar.

Uygulama: Veri seti, her bir fold içinde sınıf oranları korunacak şekilde bölünmüştür. Bu sayede model, eğitim süresince tüm sınıfları, özellikle nadir görülen lezyonları, düzenli ve dengeli bir biçimde görme imkânı elde etmiştir. Uygulanan bu strateji sonucunda, modelin performansı daha dengeli, güvenilir ve genellenebilir hale gelmiştir.

Veri Ön İşleme & Augmentation


Hazırlık: Görüntüler, modele giriş olarak kullanılmadan önce 224×224 boyutlarına yeniden ölçeklendirilmiş ve normalize edilmiştir.

Data Augmentation Uygulamaları


–**Random Flip ve Rotation:** Farklı bakış açıları ve pozisyon değişimlerine karşı modelin genelleme yeteneğini artırmak amacıyla uygulanmıştır.

–**Color Jitter:** Aydınlatma, parlaklık ve kontrast değişimlerine karşı modelin daha dayanıklı hâle gelmesi hedeflenmiştir.

Sonuç:Uygulanan veri artırma teknikleri sayesinde modelin genelleme kabiliyeti artırılmış ve aşırı öğrenme (overfitting) riskinin azaltılmasına katkı sağlanmıştır.



Random Horizontal Flip



Color Jitter

Resize to 224x224°

Çözmeyi Amaçladığı Sorunlar

Sınıf Dengesizliği: Verinin %67'sinin Nevüs (nv) olması nedeniyle modellerin nadir ama tehlikeli kanser türlerini (Melanom gibi) göz ardı etmesini engellemek.

Görsel Benzerlik: İyi ve kötü huylu lezyonlar arasındaki yüksek benzerlikten kaynaklanan yanlış teşhis riskini minimize etmek.

Açıklanabilirlik: Grad-CAM ile modelin karar verme sürecini görselleştirerek doktorlara şeffaf bir destek sunmak.

Mimari Seçimi: 9 farklı model arasından (ResNet, EfficientNet vb.) klinik teşhis için en verimli yapıyı belirlemek.

Performans Metrikleri & Başarı Kriterleri


Accuracy: Genel başarıyı ölçtük.
(**Accuracy ≥ 0.80**)

F1-Score: Sınıf dengesizliği olduğu için en temel kriterimiz bu oldu.
(**F1-Score ≥ 0.75**)



ROC-AUC (multiclass): Modelin sınıfları eşik değerlerinden bağımsız olarak ayırt etme başarısını ölçmek için kullanılmıştır.
ROC-AUC ≥ 0.80 , güçlü bir ayırım kabiliyetine işaret etmektedir.

Precision & Recall: Yanlış negatiflerin (kanserliyi sağlıklı bulma) önüne geçmek için analiz edildi.

Örnek:EfficientNet-B3 Confusion Matrix'i



Örnek Grafikler



Eğitim Stratejisi

Loss Function: Çok sınıflı bir yapı olduğu için CrossEntropyLoss kullanıldı.

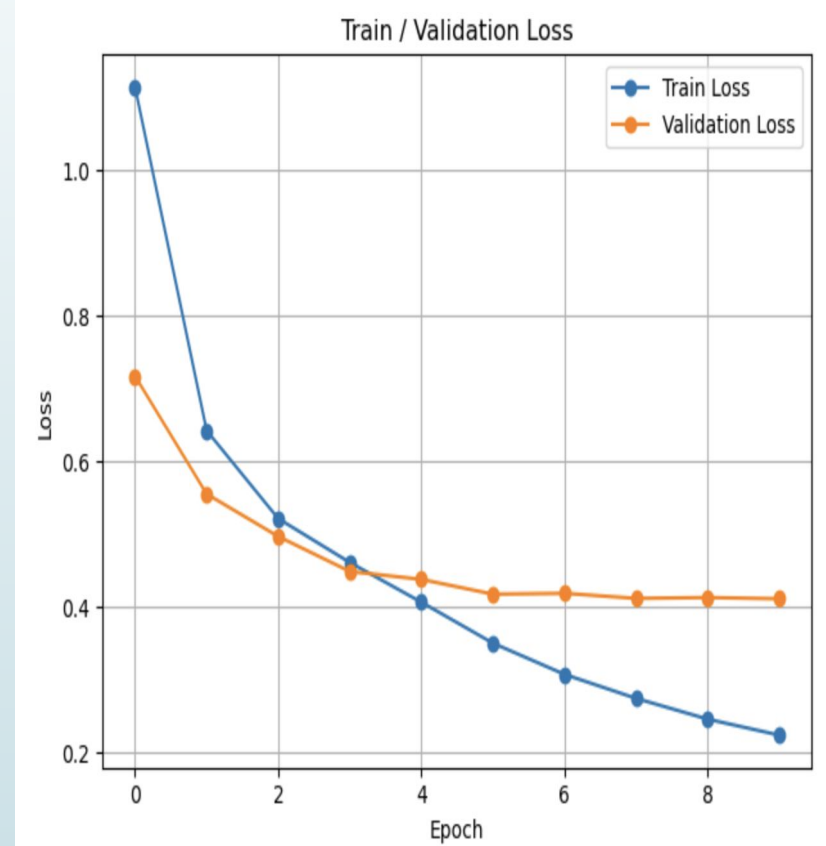
Optimizer: Dinamik öğrenme oranı yönetimi için Adam / AdamW tercih edildi.

İyileştirme Mekanizmaları:

- **Early Stopping:** Doğrulama kaybı (validation loss) 5 epoch boyunca iyileşmediğinde eğitim durdurularak overfitting önlendi.
- **Learning Rate Scheduler (Öğrenme Hızı Zamanlayıcısı):** Eğitim sırasında öğrenme hızını sabit tutmak yerine dinamik olarak ayarladık.

Batch Size Seçimi: Eğitim sürecimizde bellek kapasitesini ve gradyan gürültüsünü dengelemek adına farklı değerler (örn: 16, 32, 64) test edilmiştir.

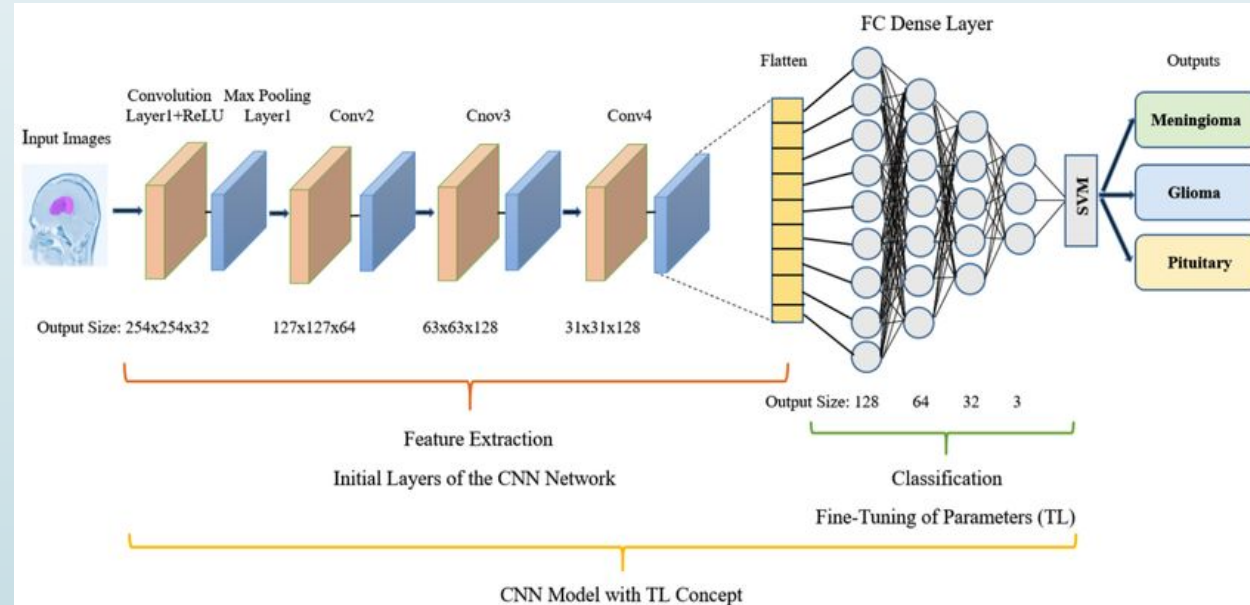
EfficientNet-B1 Loss Grafiği



Temel Tasarım Kararları

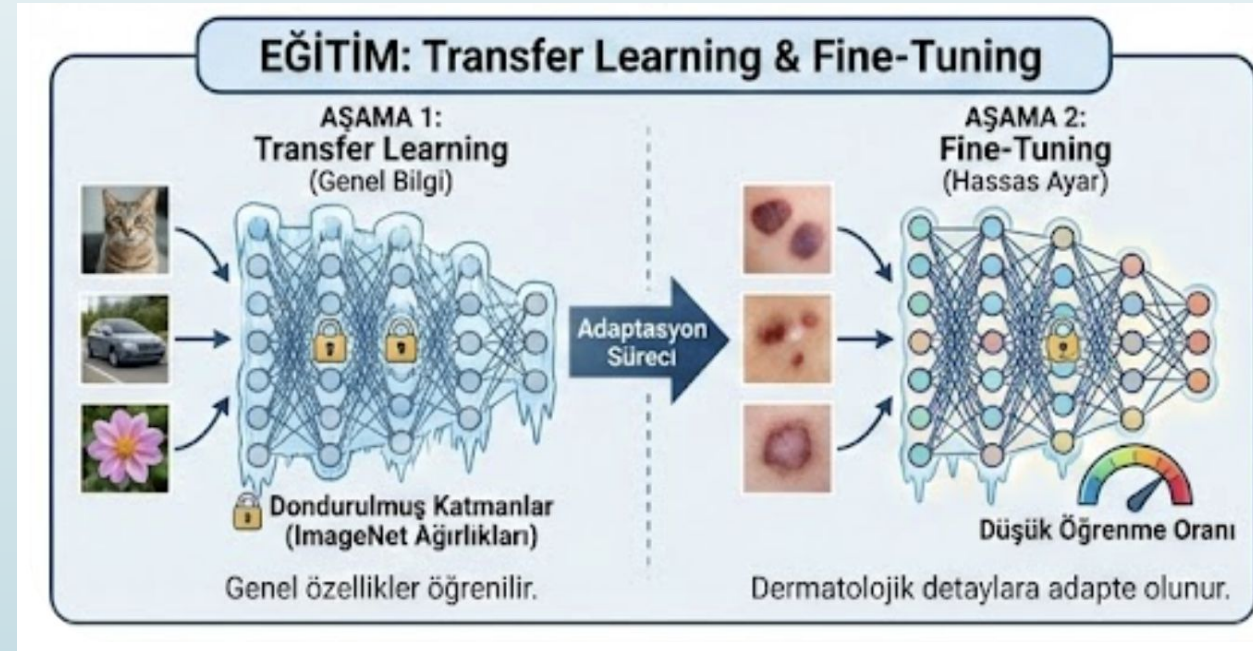
Çalışmanın temel yaklaşımı ve tasarımı, "Tek bir model yerine, geniş bir mimari yelpazesiyle en doğru klinik karara ulaşma" stratejisi üzerine kurulmuştur.

Mimari Çeşitlilik ve Kıyaslama: Projede sadece bir modelle yetinilmemiş; ResNet (18, 34, 50, 101), EfficientNet (B0, B1, B3), DenseNet-121 ve Xception gibi 9 farklı derin öğrenme mimarisi aynı şartlar altında yarıştırmıştır. Bu yaklaşım, verisetine en uygun (optimal) derinliği ve yapıyı belirlememize olanak sağlamıştır.




İki Aşamalı Eğitim Stratejisi (Transfer Learning & Fine-Tuning): Modeller önce ImageNet ağırlıklarıyla dondurulmuş katmanlarla eğitilmiş, ardından tüm katmanlar düşük öğrenme oranıyla (Fine-tuning) hassas ayara tabi tutulmuştur. Bu sayede modellerin genel nesne özelliklerinden sıyrılıp dermatolojik detaylara adapte olması sağlanmıştır.

Sınıf Dengesizliğiyle Mücadele: Veri setindeki dengesizliği (NV sınıfının yoğunluğu) çözmek için eğitim sırasında sınıf ağırlıkları (Class Weights) kullanılmıştır. Bu karar, toplam doğruluktan ziyade, hayati önem taşıyan "Kanser (MEL) yakalama oranını" artırmayı hedeflemiştir.



Açıklanabilirlik ve Güven (Grad-CAM): Yapay zekanın "kara kutu" doğasını kırmak adına Grad-CAM entegrasyonu yapılmıştır. Bu tasarım kararı, modelin görselin hangi spesifik bölgesine odaklandığını ısı haritalarıyla somutlaştırarak doktorlara gerekçelendirilmiş bir karar desteği sunmaktadır.

Klinik Gruplandırma Yaklaşımı: 7 farklı hastalık sınıfı, "Kanser, Ön-Kanser ve İyi Huylu" olarak klinik kategorilere ayrılarak analiz edilmiştir. Bu, modelin sadece teknik bir sınıflandırıcı değil, gerçek dünyada hayat kurtarabilecek bir ön tarama aracı olarak konumlandırılmasını sağlamıştır.



Modeller

 Üye	 Sorumlu Olduğu Modeller	 Model Karakteristiği
Zeynep Ekinici	Xception & ResNet18	Ayrılabilir evrişimler ve hızlı temel mimariler.
Şevval Arslan	EfficientNet-B0 & ResNet50	Optimize edilmiş baz model ve orta derinlikte residual yapı.
Zeynep Şafak	EfficientNet-B3 & ResNet34	Yüksek çözünürlüklü ölçekleme ve verimli residual bağlantılar.
Miyase Eda Erol	EfficientNet-B1& DenseNet121	Gelişmiş ölçekleme ve yoğun katmanlar arası bilgi akışı.
Eylül Erdemci	EfficientNet-B0 & ResNet101	Baz model karşılaştırması ve çok derin mimari analizi.



Genel Model Karşılaştırması

Model (Geliştirici)	Mimari	BalancedAccuracy	F1-Score (Macro)	Precision (Macro)	Recall (Macro)	ROC-AUC (Macro-OVR)
Model 1 (Şevval Arslan)	Efficient-B0	0.82	0.78	0.75	0.82	0.97
Model 1 (Şevval Arslan)	ResNet50	0.84	0.81	0.79	0.85	0.97
Model2 (Zeynep Ekinici)	ResNet18	0.83	0.68	0.83	0.83	0.96
Model2 (Zeynep Ekinici)	Xception	0.81	0.60	0.80	0.81	0.94
Model3(Zeynep Şafak)	ResNet-34	0.84	0.72	0.77	0.69	0.96
Model3(Zeynep Şafak)	EfficientNet-B3	0.90	0.81	0.84	0.78	0.97
Model4(Eda Erol)	EfficientNet-B1	0.86	0.76	0.78	0.74	0.96
Model4(Eda Erol)	DenseNet-121	0.80	0.77	0.74	0.83	0.95
Model5(Eylül)	ResNet101	0.70	0.11	0.10	0.14	0.9056
Model5 (Eylül)	EfficientB0	0.73	0.11	0.10	0.14	0.9080

Genel Model Karşılaştırma Tablosunun Yorumu

Görseldeki karşılaştırma tablosu, 9 farklı derin öğrenme modelinin performansını özetlemekte ve **EfficientNet-B3** modelinin %90 doğruluk (Accuracy) ve 0.97 ROC-AUC skoruyla en başarılı mimari olduğunu göstermektedir. Tablodaki en dikkat çekici bulgu, çok derin bir model olan **ResNet-101**'in %73 gibi düşük bir başarıda kalmasıdır; bu durum, model derinliğinden ziyade mimari verimliliğin tıbbi teşhislerde daha önemli olduğunu kanıtlamaktadır.

Ayrıca **Xception** ve **ResNet-18** gibi modellerin F1 skorlarının düşük kalması, bu modellerin nadir görülen kanserli sınıfları ayırt etmekte zorlandığını ortaya koymaktadır. Buna karşın **DenseNet-121**, %86'lık yüksek kesinlik (Precision) oranıyla hatalı teşhis riskini azaltan güvenilir bir alternatif olarak öne çıkmaktadır. Özetle tablo, deri lezyonlarını analiz etmede **EfficientNet** serisinin klasik derin ağlara göre çok daha yüksek bir öğrenme kapasitesine sahip olduğunu doğrulamaktadır.



Sınıf Bazlı Karşılaştırma (F1-Skor Analizi)

Sınıflar / Modeller	Eff-B3 (Zeynep Ş.)	Eff-B1 (Eda)	Res-50 (Şevval)	Res-34 (Zeynep Ş.)	Dense-121 (Eda)	Eff-B0 (Şevval)
MEL (Kanser)	0.76	0.68	0.72	0.60	0.61	0.69
NV (Benign)	0.95	0.93	0.94	0.92	0.88	0.93
BCC	0.84	0.79	0.79	0.75	0.78	0.80
AKIEC	0.79	0.67	0.71	0.61	0.64	0.73
BKL	0.82	0.70	0.74	0.70	0.73	0.76
VASC	0.88	0.87	0.95	0.74	0.87	0.87
DF	0.62	0.67	0.86	0.72	0.91	0.69

Devamı

Sınıflar / Modeller	Res-18 (Zeynep E.)	Xception (Zeynep E.)	Eff-B0 (Eylül)	Res-101 (Eylül)
MEL (Kanser)	0.49	0.51	0.00	0.00
NV (Benign)	0.91	0.90	0.80	0.78
BCC	0.60	0.56	0.00	0.00
AKIEC	0.61	0.58	0.00	0.26
BKL	0.69	0.63	0.00	0.00
VASC	0.79	0.71	0.00	0.45
DF	0.67	0.30	0.00	0.00

Sınıf Bazlı Karşılaştırma Tablosunun Açıklaması

Görseldeki tablolar, farklı derin öğrenme modellerinin cilt lezyonlarını teşhis etme başarısını (F1-Skoru) karşılaştırmaktadır.

Genel olarak tüm modeller, **NV (Benign)** sınıfında en yüksek başarıyı (0.87 - 0.95 arası) sergilemiştir. Modeller arasında **Eff-B3**, hem kanserli hücrelerin (**MEL**) hem de diğer sınıfların tespitinde en dengeli ve yüksek performansı gösteren model olarak öne çıkmaktadır. Buna karşın, **Res-101** ve **Eff-B0 (Eylül)** modelleri, özellikle **MEL (Kanser)** ve **AKIEC** gibi sınıflarda oldukça düşük skorlar almış.Özetle; Eff-B3 ve Res-50 gibi modeller daha güvenilir sonuçlar verirken, bazı modellerin belirli hastalık türlerini ayırt etmede ciddi yetersizlikleri bulunmaktadır.

EfficientNet-B3 Classification Report

	precision	recall	f1-score	support
0	0.82	0.76	0.79	49
1	0.84	0.84	0.84	77
2	0.89	0.76	0.82	165
3	0.75	0.53	0.62	17
4	0.77	0.76	0.76	167
5	0.93	0.97	0.95	1006
6	0.90	0.86	0.88	22
accuracy			0.90	1503
macro avg	0.84	0.78	0.81	1503
weighted avg	0.90	0.90	0.90	1503

Model 1 (SkinClassifierCNN): ResNet50 / EfficientNet-B0 (Geliştirici: Şevval Arslan)

Efficient-B0 (Şevval Arslan)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.65	0.73	0.69	223
NV (Benign)	0.96	0.90	0.93	1341
BCC	0.75	0.85	0.80	103
AKIEC	0.71	0.75	0.73	65
BKL (Benign Keratoz)	0.71	0.82	0.76	220
VASC (Vasküler Lezyon)	0.81	0.93	0.87	28
DF (Dermatofibroma)	0.62	0.78	0.69	23

ResNet50 (Şevval Arslan)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.73	0.70	0.72	223
NV (Benign)	0.95	0.93	0.94	1341
BCC	0.70	0.89	0.79	103
AKIEC	0.65	0.78	0.71	65
BKL (Benign Keratoz)	0.75	0.74	0.74	220
VASC (Vasküler Lezyon)	0.93	0.96	0.95	28
DF(Dermatofibroma)	0.81	0.91	0.86	23

Model 2: ResNet18 / Xception (Geliştirici: Zeynep Ekinci)

ResNet18 (Zeynep Ekinci)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.70	0.38	0.50	223
NV (Benign)	0.86	0.98	0.91	1341
BCC	0.85	0.49	0.63	103
AKIEC	0.70	0.55	0.62	65
BKL (Benign Keratoz)	0.73	0.64	0.68	220
VASC (Vasküler Lezyon)	0.77	0.81	0.79	28
DF (Dermatofibroma)	0.71	0.63	0.67	23

Xception (Zeynep Ekinci)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.71	0.40	0.51	223
NV (Benign)	0.88	0.96	0.92	1341
BCC	0.54	0.58	0.56	103
AKIEC	0.61	0.57	0.59	65
BKL (Benign Keratoz)	0.66	0.64	0.65	220
VASC (Vasküler Lezyon)	0.71	0.71	0.71	28
DF (Dermatofibroma)	0.36	0.26	0.30	23

Model 3 (SafakCNN): ResNet34 / EfficientNet-B3 (Geliştirici: Zeynep Şafak)

ResNet34 (Zeynep Şafak)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.66	0.54	0.60	223
NV (Benign)	0.89	0.95	0.92	1341
BCC	0.87	0.66	0.75	103
AKIEC	0.57	0.66	0.61	65
BKL(Benign Keratoz)	0.76	0.66	0.70	220
VASC(Vasküler Lezyon)	0.94	0.61	0.74	28
DF (Dermatofibroma)	0.71	0.74	0.72	23

EfficientNet-B3 (Zeynep Şafak)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.77	0.76	0.76	167
NV (Benign)	0.93	0.97	0.95	1006
BCC	0.84	0.84	0.84	77
AKIEC	0.82	0.76	0.79	49
BKL (Benign Keratoz)	0.89	0.76	0.82	165
VASC (Vasküler Lezyon)	0.90	0.86	0.88	22
DF (Dermatofibro ma)	0.75	0.53	0.62	17

Model 4 (BaseCNN): EfficientNet-B1 / DenseNet-121 (Geliştirici: Miyase Eda Erol)

EfficientNet-B1 (MiyaseEda Erol)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.72	0.64	0.68	223
NV (Benign)	0.92	0.95	0.93	1341
BCC	0.82	0.77	0.79	103
AKIEC	0.67	0.68	0.67	65
BKL(Benign Keratoz)	0.70	0.70	0.70	220
VASC(Vasküler Lezyon)	0.92	0.82	0.87	28
DF(Dermatofibro ma)	0.68	0.65	0.67	23

DenseNet-121 (MiyaseEda Erol)	Precisi on	Recall	F1-Score	Suppo rt
MEL (Kanser)	0.47	0.87	0.61	223
NV (Benign)	0.97	0.80	0.88	1341
BCC	0.71	0.86	0.78	103
AKIEC	0.64	0.65	0.64	65
BKL(Benign Keratoz)	0.71	0.75	0.73	220
VASC (Vasküler Lezyon)	0.79	0.96	0.87	28
DF(Dermatofibr oma)	0.91	0.91	0.91	23

Model 5 EfficientNet-B0 / ResNet101 (Geliştirici: Eylül Erdemci)

Efficient- B0 (Eylül Erdemci)	Precision	Recall	F1-Score	Support
MEL (Kanser)	0.00	0.00	0.00	167
NV (Benign)	0.67	1.00	0.80	1006
BCC	0.00	0.00	0.00	77
AKIEC	0.00	0.00	0.00	49
BKL(Beni gnKeratoz)	0.00	0.00	0.00	165
VASC (Vasküler Lezyon)	0.00	0.00	0.00	22
DF(Derma tofibroma)	0.00	0.00	0.00	17

Res- Net101 (Eylül Erdemci)	Precision	<u>Recall</u>	F1-Score	<u>Sup port</u>
MEL (Kanser)	0.00	0.00	0.00	167
NV (<u>Benign</u>)	0.67	1.00	0.80	1006
BCC	0.00	0.00	0.00	77
AKIEC	0.00	0.72	0.00	49
<u>BKL(Benign Keratoz)</u>	0.00	0.00	0.00	165
VASC (Vasküler Lezyon)	0.00	0.65	0.45	22
<u>DF(Dermatof ibroma)</u>	0.00	0.00	0.00	17

Deneyisel Bulgular ve Analizler

Deneyisel sonuçlar, **EfficientNet-B3** mimarisinin hem genel doğrulukta hem de melanom tespitinde en dengeli ve yüksek performansı sunduğunu göstermiştir. Bulgular, çok derin modellerin her zaman daha iyi sonuç vermediğini ve **sınıf dengesizliğinin** özellikle kanser sınıflarında performansı olumsuz etkilediğini ortaya koymuştur. **DenseNet-121**, belirli sınıflarda yüksek başarıyla sınıf bazlı uzmanlaşma potansiyeli göstermiştir. **Grad-CAM** analizleri, modellerin doğru tahminlerde lezyonun kritik bölgelerine odaklandığını, **ROC-AUC değerleri** ise sınıfları ayırt etme yeteneğinin yüksek olduğunu kanıtlamıştır. Genel olarak sistem, doktorları destekleyen **güvenilir bir klinik karar destek sistemidir**.

Sürecin Öğrettikleri

Metriklerin Önemi: Tıbbi yapay zekada sadece genel "Doğruluk" (Accuracy) oranına bakmanın yanıltıcı olabileceği; hayati kararlarda F1-Skoru ve Recall (duyarlılık) değerlerinin asıl başarı kriteri olduğu öğrenilmiştir.

Veri Dengesizliğiyle Mücadele: HAM10000 gibi dengesiz veri setlerinde, model eğitime dahil edilen sınıf ağırlıkları (class weights) stratejisinin, nadir ama ölümcül kanser türlerini yakalamada ne kadar kritik bir fark yarattığı deneyimlenmiştir.

Hibrit Yaklaşım İhtiyacı: Farklı modellerin farklı sınıflarda (örneğin DenseNet-121'in DF sınıfında %91 F1 başarısı gibi) uzmanlaştığı görülmüş; bu da gelecekte tek bir model yerine bir topluluk (ensemble) yapısının daha güçlü sonuçlar vereceğini öğretmiştir.

Çıkarımlar

Kanser Teşhisi (MEL): Projemizin en kritik hedefi olan Melanom (MEL) teşhisinde, EfficientNet-B3 %76 F1-skoru ile açık ara en başarılı modeldir. Diğer modeller bu sınıfta zorlanırken, B3 mimarisi karmaşık deri yapılarını daha iyi ayırt etmiştir.

Veri Dengesi Etkisi: Tüm modellerde en yüksek başarı NV (Ben) sınıfında gelmiştir (%90+). Bunun sebebi veri setimizdeki görüntülerin çoğunluğunun bu sınıfa ait olmasıdır.

Küçük Sınıf Başarısı (DF): DenseNet-121 modelinin Dermatofibroma (DF) sınıfında %91 skor alması dikkat çekicidir. Bu, yoğun bağlantılı katmanların az sayıda veri içeren sınıflarda bazen daha iyi özellik yakalayabildiğini gösteriyor.

Ulaşılan Sonuçlar

En Uygun Mimari Tespiti: 9 farklı model arasında yapılan kıyaslamalar sonucunda, EfficientNet-B3'ün %90 doğruluk ve 0.76 kanser F1-skoru ile en dengeli ve güvenilir performansı sunduğu görülmüştür.

Model Derinliği Paradoksu: Çok derin mimarilerin (ResNet-101 gibi) tıbbi görüntülerde her zaman daha iyi sonuç vermediği; aksine, daha sık ve optimize modellerin (ResNet-18) kısıtlı veriye sahip sınıflarda daha dirençli olduğu kanıtlanmıştır.

Klinik Güvenilirlik: Modellerin ROC-AUC değerlerinin 0.95 ve üzeri olması, sistemin farklı lezyon türlerini birbirinden ayırt etme yeteneğinin uzman düzeyine yaklaştığını göstermiştir.

Yorumlanabilirlik: Grad-CAM analizi ile yapay zekanın teşhis koyarken lezyonun asimetric kenarları gibi tıbbi açıdan anlamlı bölgelere odaklandığı somut bir şekilde doğrulanmıştır.

Neden Heyecan Verici?

Bu çalışma, 9 farklı derin öğrenme mimarisini aynı klinik standartlarda yarıştırmak, cilt kanseri teşhisinde sadece yüksek doğruluğa değil, EfficientNet-B3 ve DenseNet-121 gibi modellerle en nadir ama en tehlikeli lezyonları yakalamaya odaklanan güvenilir bir hiyerarşi sunmaktadır.

Geliştirdiğimiz sistem, Grad-CAM teknolojisi sayesinde yapay zekanın 'kara kutu' doğasını kırarak, teşhis sürecini doktorlar için görsel olarak açıklanabilir ve doğrulanabilir bir şeffaflığa kavuşturmuştur.

Sınıf dengesizliği ve görsel benzerlik gibi kritik tıbbi engelleri yenilikçi ağırlıklandırma stratejileriyle aşan bu proje, erken teşhis potansiyeliyle hayat kurtarabilecek yüksek hassasiyetli bir dijital karar destek mekanizması ortaya koymaktadır.

TEŞEKKÜRLER.

Projemizin github linkine aşağıdaki karekod'dan ulaşabilirsiniz.

